



3강 실습



좋은 데이터와 나쁜 데이터

데이터 품질을 점검하고,
좋은 데이터로 만드는 실습



실습 목표

문제 있는 데이터를 발견하고,
좋은 데이터로 정제해 봅시다.



사용 데이터

student_survey_dirty.csv
(문제 데이터)



예상 소요 시간

약 120분



실습 구성

따라하기 (Part 1)
+ 미니 프로젝트 (Part 2)

상황 제시

학과 만족도 조사 결과를 받았습니다.
이 데이터를 믿고 **교육과정을 개편**하시겠습니까?

상황



우리 대학은 학생 만족도 조사를 실시했습니다.
설문 결과를 바탕으로 다음 학기의
교육과정 개편 방향을 결정하려고 합니다.

하지만 이 데이터에 문제가 있다면?
잘못된 분석은 잘못된 의사결정으로 이어집니다.

! 데이터 품질을 먼저 확인하는 것이 중요합니다!

제공 데이터 미리보기 (일부)

학번	학과	성별	만족도(1~5)	설문일자
2025001	컴퓨터공학	M	5	2025-03-10
2025002	전자공학	F	4	2025-03-11
2025003	컴퓨터공학	M	3	2025-03-12
...	...	...	...	...
2025006	컴퓨터공학	M	4	2025-03-15
2025007	컴퓨터공학	남	5	2025-03-16
2025014	전자공학	F	4	2025-03-21
2025015	전자공학	F	-5	2025-03-22

※ 실제 데이터에는 결측값, 중복값, 이상치, 표기 불일치, 오래된 데이터 등이 포함되어 있습니다.

실습에서 다룰 질문



이 데이터에는
어떤 문제가 있을까?



문제 있는 데이터를
어떻게 정리할까?



데이터 품질은
어떻게 평가할까?



좋은 데이터로 만든 후,
어떤 인사이트를 얻을 수 있을까?

3강 실습



데이터 불러오기

CSV 파일을 불러와 데이터의 기본 정보를 확인합니다.
데이터의 구조와 타입을 파악하는 단계입니다.



핵심 포인트

- 데이터를 정확히 불러왔는지 확인
- 컬럼명과 데이터 타입 파악
- 행과 열의 크기 확인
- 기본 통계값으로 데이터 감 잡기

Python 코드 예시

```
1 # 필요한 라이브러리 불러오기
2 import pandas as pd
3
4 # CSV 파일 불러오기
5 df = pd.read_csv('student_survey_dirty.csv')
6
7 # 기본 정보 확인
8 print(df.info())
9 df.head()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 6 columns):
#   Column          Non-Null Count  Dtype
---  -
0   학번            998 non-null   int64
1   학과            995 non-null   object
2   성별            997 non-null   object
3   만족도(1~5)     990 non-null   float64
4   출석률(%)       1000 non-null  float64
5   설문일자        995 non-null   object
dtypes: float64(2), int64(1), object(3)
memory usage: 47.0+ KB
```

데이터 미리보기 (일부)

학번	학과	성별	만족도(1~5)	출석률(%)	설문일자
2025001	컴퓨터공학	M	5	95	2025-03-10
2025002	전자공학	F	4	88	2025-03-11
2025003	컴퓨터공학	M	3	90	2025-03-12
...	...	...	...	...	...
2025006	컴퓨터공학	M	4	110	2025-03-15
2025007	컴퓨터공학	남	5	93	2025-03-16
2025008	전자공학	Female	4	89	2025-03-17
2025009	전자공학	F	3	87	2024-01-05
...	...	...	...	...	...
2025014	전자공학	F	4	-5	2025-03-21

⚠️ 확인할 점

- ✓ 성별 컬럼에 '남', 'Female' 등 표기 불일치
- ✓ 출석률(%)에 110, -5 등 이상치 존재
- ✓ 설문일자가 과거(2024-01-05)로 잘못 입력된 값 존재

3강 실습



결측값 찾기

데이터 분석의 정확성을 위해
결측값을 확인하고 처리해야 합니다.



핵심 포인트

- 결측값 개수 확인
- 결측 비율(%) 계산
- 변수별 결측 분포 파악
- 이상치와 결측값 혼동 주의

Python 코드 예시

```
1 # 결측값 개수 확인
2 missing_count = df.isnull().sum()
3 missing_count
4
5 # 결측 비율(%) 계산
6 missing_percent = (df.isnull().mean() * 100).round(2)
7 missing_summary = pd.DataFrame({
8     '결측 개수': missing_count, '결측 비율(%)': missing_percent})
8 missing_summary.sort_values('결측 비율(%)', ascending=False)
```

결과 예시

	결측 개수	결측 비율(%)
설문일자	5	0.50
출석률(%)	3	0.30
성별	2	0.20
만족도(1~5)	1	0.10
학과	0	0.00
학번	0	0.00

데이터 미리보기 (일부)

학번	학과	성별	만족도(1~5)	출석률(%)	설문일자
2025001	컴퓨터공학	M	5	95	2025-03-10
2025002	전자공학	F	4	88	2025-03-11
2025003	컴퓨터공학	M	3	90	2025-03-12
...	...	...	...	...	...
2025006	컴퓨터공학	M	4	110	2025-03-15
2025007	컴퓨터공학	남	5	93	2025-03-16
2025008	전자공학	Female	4	89	2025-03-17
2025009	전자공학	F	3	87	2024-01-05
...	...	...	...	...	...
2025014	전자공학	F	4	-5	2025-03-21

⚠️ 확인할 점

- ✓ 설문일자에 결측값 5개 존재
- ✓ 성별에 결측값 2개 존재
- ✓ 출석률(%)에 결측값 3개 존재
- ✓ 결측 비율이 높은 변수부터 처리 우선순위 결정



다음 단계

결측 비율과 데이터 특성을 고려하여 적절한 처리 방법을 선택합니다.

결측값 확인



처리 방법 결정



데이터 처리



결과 확인



3강 실습



중복 데이터 찾기

분석의 정확성을 위해 중복 데이터를 확인하고 적절히 처리해야 합니다.



핵심 포인트

- 완전 중복 행 확인
- 어떤 기준으로 중복을 판단할지 결정
- 중복 데이터가 발생한 원인 파악
- 중복 처리 방법 결정
(제거, 통합, 최신값 유지 등)

Python 코드 예시

```
1 # 완전 중복 행 확인
2 duplicate_rows = df.duplicated()
3 duplicate_count = duplicate_rows.sum()
4
5 # 중복된 행만 조회
6 duplicate_df = df[duplicate_rows].sort_values('설문일자')
7
8 # 특정 컬럼 기준으로 중복 확인 (예: 학번, 설문일자 조합)
9 subset_duplicates = df.duplicated(subset=['학번', '설문일자'],
10                                     keep=False)
11 subset_duplicate_df = df[subset_duplicates].sort_values('학번')
```

결과 예시

- 완전 중복 행 개수 : 3
- 부분 중복 (학번+설문일자) 개수 : 2

완전 중복 행 (일부)

학번	학과	성별	만족도(1~5)	설문일자	설문ID
2025003	컴퓨터공학	M	3	2025-03-12	S0003
2025003	컴퓨터공학	M	3	2025-03-12	S0004
2025008	전자공학	Female	4	2025-03-17	S0008
2025008	전자공학	Female	4	2025-03-17	S0009
2025008	전자공학	Female	4	2025-03-17	S0010

데이터 미리보기 (일부)

학번	학과	성별	만족도(1~5)	설문일자	설문ID
2025001	컴퓨터공학	M	5	2025-03-10	S0001
2025002	전자공학	F	4	2025-03-11	S0002
2025003	컴퓨터공학	M	3	2025-03-12	S0003
2025003	컴퓨터공학	M	3	2025-03-12	S0004
2025004	전자공학	F	5	2025-03-13	S0005
...	...	...	...	...	...
2025007	컴퓨터공학	남	5	2025-03-16	S0007
2025008	전자공학	Female	4	2025-03-17	S0008
2025008	전자공학	Female	4	2025-03-17	S0009
2025008	전자공학	Female	4	2025-03-17	S0010
...	...	...	...	...	...
2025015	전자공학	F	-5	2025-03-22	S0016

⚠️ 확인할 점

- ✓ 완전 중복 행 3개 존재
- ✓ 학번+설문일자 기준 중복 2개 존재
- ✓ 중복 데이터는 분석 결과를 왜곡할 수 있음
- ✓ 중복 발생 원인을 파악 후 적절한 처리 방법을 선택해야 함



다음 단계

중복 데이터를 검토하고, 데이터 특성에 맞는 처리 방법을 선택합니다.

중복 데이터 검토



처리 방법 결정



데이터 처리



다음 단계로 진행

3강 실습



이상치 탐지

데이터의 분포를 이해하고,
이상치(outlier)를 탐지하여
분석의 신뢰성을 높여야 합니다.



핵심 포인트

- 이상치의 개념 이해
- IQR 방법으로 이상치 탐지
- Z-점수 방법으로 이상치 탐지
- 이상치가 분석 결과에 미치는 영향 고려

이상치 탐지 방법



IQR 방법

Q1 - 1.5×IQR 미만 또는 Q3 + 1.5×IQR 초과 값을 이상치로 판단



Z-점수 방법

평균으로부터 3표준편차 이상 떨어진 값을 이상치로 판단 ($|Z| > 3$)

Python 코드 예시

```
1 import pandas as pd
2 import numpy as np
3
4 # 분석할 수치형 컬럼 (만족도(1~5), 출석률(%))
5 numeric_cols = ['만족도(1~5)', '출석률(%)']
6
7 # IQR 방법
8 Q1 = df[numeric_cols].quantile(0.25)
9 Q3 = df[numeric_cols].quantile(0.75)
10 IQR = Q3 - Q1
11 outlier_iqr = ((df[numeric_cols] < (Q1 - 1.5 * IQR)) | \
                  (df[numeric_cols] > (Q3 + 1.5 * IQR)))
```

이상치 탐지 결과 요약

컬럼	IQR 방법		Z-점수 방법 ($ Z > 3$)	
	이상치 개수	이상치 비율(%)	이상치 개수	이상치 비율(%)
만족도(1~5)	2	0.20	1	0.10
출석률(%)	3	0.30	2	0.20

데이터 미리보기 (일부)

학번	만족도(1~5)	출석률(%)	성별	설문일자
2025001	5	95	M	2025-03-10
2025002	4	88	F	2025-03-11
2025003	3	90	M	2025-03-12
...	...	...	...	...
2025006	4	110	M	2025-03-15
2025007	5	93	남	2025-03-16
2025008	4	89	Female	2025-03-17
2025010	4	-5	Female	2025-03-17
2025011	5	97	M	2025-03-18
...	...	...	...	...
2025015	-5	85	F	2025-03-22

: 이상치로 탐지된 데이터 예시

⚠️ 확인할 점

- ✓ 만족도에 -5, 출석률에 110, -5 등 비현실적인 값 존재
- ✓ 이상치는 분석 결과에 큰 영향을 미칠 수 있음
- ✓ 이상치 처리(제거, 수정, 대체) 여부를 신중히 결정해야 함

3강 실습



오류 데이터 처리

데이터의 신뢰성을 높이기 위해

오류 데이터를 식별하고

올바르게 수정하거나 제거해야 합니다.



핵심 포인트

- 오류 데이터의 유형 이해
- 규칙 기반으로 오류 데이터 식별
- 수정 가능한 오류는 수정
- 수정 불가능한 오류는 제거
- 데이터 일관성 유지

Python 코드 예시

```
1 # 1. 음수 값 처리 (만족도, 출석률)
2 df.loc[df['만족도(1~5)'] < 1, '만족도(1~5)'] = np.nan
3 df.loc[df['만족도(1~5)'] > 5, '만족도(1~5)'] = np.nan
4 df.loc[df['출석률(%)'] < 0, '출석률(%)'] = np.nan
5 df.loc[df['출석률(%)'] > 100, '출석률(%)'] = np.nan
6
7 # 2. 성별 값 오류 처리
8 valid_gender = ['M', 'F', '남', '여', 'Male', 'Female']
9 df.loc[~df['성별'].isin(valid_gender), '성별'] = np.nan
10
11 # 3. 날짜 형식 오류 처리
12 df['설문일자'] = pd.to_datetime(df['설문일자'], errors='coerce')
13
14 # 4. 처리 결과 확인
15 error_summary = df.isnull().sum()
```

처리 결과 요약

컬럼	오류 데이터		처리 후 결측값 개수
	발견 개수	처리 방법	
만족도(1~5)	2	범위 벗어난 값 → NaN	2
출석률(%)	2	범위 벗어난 값 → NaN	2
성별	1	허용되지 않은 값 → NaN	1
설문일자	1	형식 오류 → NaT	1
합계	6	-	6

데이터 미리보기 (일부)

학번	성별	만족도(1~5)	출석률(%)	설문일자	처리 내용
2025001	M	5	95	2025-03-10	-
2025002	F	4	88	2025-03-11	-
2025003	X	3	90	2025-03-12	성별 오류 → NaN
2025004	M	0	110	2025-03-13	만족도, 출석률 오류 → NaN
2025005	F	6	85	2025-03-14	만족도 오류 → NaN
2025006	M	4	100	2025-03-15	-
2025007	남	5	93	2025-03-16	-
2025008	Female	4	89	2025-03-17	-
2025009	F	3	87	2025/03/18	날짜 형식 오류 → NaT
2025010	여	4	-5	2025-03-19	출석률 오류 → NaN
...	...	...	...	...	...

: 오류 데이터가 식별되어 수정 또는 제거된 항목

확인할 점

- ✓ 만족도는 1~5 범위 값만 유효
- ✓ 출석률은 0~100 범위 값만 유효
- ✓ 성별은 허용된 값만 유지 (M, F, 남, 여, Male, Female)
- ✓ 설문일자는 올바른 날짜 형식으로 변환되어야 함
- ✓ 오류 데이터 처리는 분석 결과의 신뢰성을 크게 향상시킴



다음 단계

오류 데이터를 처리하여 데이터의 정확성과 일관성을 확보했습니다.

오류 데이터 처리



데이터 변환



데이터 통합



최종 데이터 확인

3강 실습



데이터 시각화

데이터를 시각적으로 표현하여
패턴과 관계를 쉽게 파악하고,
분석 결과를 효과적으로 전달합니다.



핵심 포인트

- 데이터의 분포와 추세 파악
- 변수 간 관계 시각화
- 적절한 차트 유형 선택
- 시각화를 통한 인사이트 도출
- 분석 결과를 명확하게 전달

Python 코드 예시


```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 import seaborn as sns
4
5 # 폰트 설정
6 plt.rcParams['font.family'] = 'Malgun Gothic'
7 sns.set_style('whitegrid')
8
9 df = pd.read_csv('student_survey_clean.csv')
```

데이터 미리보기 (일부)

학번	학과	성별	만족도(1~5)	출석률(%)	설문일자
2025001	컴퓨터공학	M	5	95	2025-03-10
2025002	전자공학	F	4	88	2025-03-11
2025003	컴퓨터공학	M	3	90	2025-03-12
...	...	...	...	...	...
2025014	전자공학	F	4	-5	2025-03-21


시각화 결과 예시

1. 만족도 분포 (막대그래프)




만족도 4점이 가장 많고,
1~2점 만족도는 상대적으로 적습니다.

2. 출석률 분포 (히스토그램)




출석률은 80~100% 구간에
대부분 분포되어 있습니다.

3. 만족도 vs 출석률 (산점도)



출석률이 높을수록 만족도가
높아지는 경향이 보입니다.

4. 학과별 만족도 평균 (원형 차트)



컴퓨터공학 전공 학생의
만족도 평균이 가장 높습니다.

확인할 점

- ✓ 차트 유형이 데이터 특성에 적절한가?
- ✓ 이상치가 시각적으로 확인되는가?
- ✓ 축 레이블과 제목이 명확한가?
- ✓ 시각화를 통해 인사이트를 도출했는가?



다음 단계

시각화를 통해 데이터의
패턴과 관계를 파악했습니다.

인사이트 도출



의사결정



결과 공유



3강 실습

데이터 집계와
그룹 분석

데이터를 그룹별로 집계하고
통계 지표를 계산하여 그룹 간 차이와
특징을 분석합니다.



핵심 포인트

- 그룹별 집계의 개념 이해
- 평균, 합계, 개수 등 통계 계산
- 다중 기준 그룹 분석
- 그룹 간 비교 및 해석
- 인사이트 도출 및 의사결정 연계

Python 코드 예시

```
1 import pandas as pd
2 import numpy as np
3
4 # 데이터 불러오기
5 df = pd.read_csv('student_survey_clean.csv')
6
7 # 1. 학과별 만족도 평균
8 dept_summary = df.groupby('학과')['만족도(1-5)'].agg(['mean', 'count']).reset_index()
9
10 # 2. 성별·학과별 만족도 평균
11 gender_dept_summary = df.groupby(['성별', '학과'])['만족도(1-5)'].mean().reset_index()
12
13 # 3. 만족도 구간별 응답자 수
14 satisfaction_bins = pd.cut(df['만족도(1-5)'], bins=[0,2,3,4,5,6],
15                             labels=['1-2점', '3점', '4점', '5점', '최상(5점)'])
16 satisfaction_count = df.groupby(satisfaction_bins).size().reset_index(name='응답자 수')
17
18 # 4. 결과 확인
19 dept_summary, gender_dept_summary.head(), satisfaction_count
```

데이터 미리보기 (일부)

학번	학과	성별	만족도(1-5)	출석률(%)
2025001	컴퓨터공학	M	5	95
2025002	전자공학	F	4	88
2025003	컴퓨터공학	M	3	90
...	...	...	...	...
2025014	전자공학	F	4	-5

분석 결과 예시

1. 학과별 만족도 평균

학과	평균 만족도	응답자 수
컴퓨터공학	4.21	76
전자공학	3.72	64
기계공학	3.45	56
산업공학	3.98	50

컴퓨터공학의 만족도 평균이
가장 높습니다.

2. 성별·학과별 만족도 평균 (일부)

성별	학과	평균 만족도
M	컴퓨터공학	4.35
F	컴퓨터공학	4.05
M	전자공학	3.82
F	전자공학	3.61


모든 학과에서 남학생의 만족도가
소폭 더 높게 나타났습니다.

3. 만족도 구간별 응답자 수

만족도 구간	응답자 수	비율(%)
1-2점	18	9.0
3점	41	20.5
4점	72	36.0
5점	69	34.5
최상(5점)	0	0.0

4~5점(긍정 응답)이 전체의
70.5%를 차지합니다.

4. 만족도 평균 비교 (막대그래프)



확인할 점

- ✓ 그룹별 응답자 수가 충분한지 확인 (특히 소수 그룹)
- ✓ 평균 외에 중간값, 표준편차 등 추가 지표도 함께 고려
- ✓ 이상치, 결측값이 집계 결과에 영향을 주지 않는지 검토
- ✓ 분석 결과가 실제 의사결정에 어떤 의미를 가지는지 해석



다음 단계

그룹 분석 결과를 바탕으로
개선이 필요한 영역을 도출합니다.

문제 영역 도출



개선안 수립



의사결정

3강 실습



데이터 기반 의사결정 도출

분석 결과를 종합하여 핵심 인사이트를 도출하고, 이를 기반으로 실질적인 의사결정을 제안합니다.



핵심 포인트

- 분석 결과 종합 및 해석
- 핵심 인사이트 도출
- 문제 정의 → 대안 → 의사결정 구조화
- 데이터 기반 의사결정의 중요성
- 실행 계획 수립 및 성과 지표 설정




주요 인사이트

- ✓ 출석률 80% 이상 구간에서 만족도가 급격히 상승합니다.
- ✓ 출석률이 가장 큰 불만 요인이며, 개선 시 만족도 향상 효과가 큼.
- ✓ 남학생 만족도가 여학생보다 낮아 성별 맞춤형 지원이 필요합니다.
- ✓ 강의 내용은 강점으로 유지하고, 출석을 개선에 우선 집중해야 합니다.

Python 코드 예시

```
1 import pandas as pd
2 import numpy as np
3
4 # 분석 결과 데이터 (예시 요약 테이블)
5 summary = pd.DataFrame([
6     '항목': ['전체 평균 만족도', '4~5점 비율', '최대 불만 요인',
7             '성별 격차(M-F)', '핵심 Insight'],
8     '값/내용': [3.84, '70.5%', '출석률 (89%)',
9                 -0.30, '출석률 개선 시 만족도 상승 효과 큼']
10 ])
11
12 # 권장 의사결정 (예시)
13 recommendation = "출석률을 높이기 위한 대책을 우선 시행하고, \" \
14                   \"4~5점 만족도 비율을 75% 이상으로 향상시킨다.\"
15 summary
```

인사이트 시각 요약



의사결정 제안 (권장안)

- 1 출석률 80% 이상 구간에서 만족도가 급격히 상승합니다.
- 2 출석률이 가장 큰 불만 요인이며, 개선 시 만족도 향상 효과가 큼.
- 3 남학생 만족도가 여학생보다 낮아 성별 맞춤형 지원이 필요합니다.
- 4 강의 내용은 강점으로 유지하고, 출석을 개선에 우선 집중해야 합니다.



성과 지표 및 목표

지표	현재	목표 (다음 학기)	측정 주기
4~5점 만족 비율	70.5%	75% 이상	매 학기
출석률 80% 이상 비율	58%	75% 이상	매 학기
전체 평균 만족도	3.84	4.10 이상	매 학기
성별 만족도 격차 (M-F)	-0.30	-0.10 이하	매 학기



다음 단계

인사이트 기반
문제 정의



대안 도출
(실행 가능한 방안)



영향도/우선순위
평가



최종 의사결정
(액션 플랜 확정)



실행 및 모니터링



성과 평가 및
지속적 개선



3강 실습



최종 프로젝트

실제 데이터를 활용하여 문제를 정의하고, 분석부터 인사이트 도출, 의사결정 제안까지 수행하는 데이터 기반 의사결정 프로젝트입니다.



프로젝트 목적

- 실제 데이터를 활용한 분석 경험 축적
- 데이터 기반 의사결정 프로세스 체득
- 분석 결과를 스토리텔링으로 전달
- 팀 협업 및 문제 해결 역량 강화
- 실무 관점의 인사이트 도출 및 제안



프로젝트 주제 예시

- 1 학생 만족도 분석 및 개선 방안 제안
- 2 강의 평가 데이터 분석 및 교육 품질 향상 방안
- 3 도서관 이용 데이터 분석 및 서비스 개선 제안
- 4 교내 식당 매출-메뉴 선호도 분석 및 메뉴 최적화
- 5 졸업생 진로 데이터 분석 및 취업 지원 전략 제안

※ 팀별로 주제 선정 가능 (자유 주제 허용)

★ 성공적인 프로젝트를 위한 TIP

- 데이터와 비즈니스 맥락을 함께 고려하세요.
- 시각화로 메시지를 효과적으로 전달하세요.
- 가설을 세우고 논리적으로 검증하세요.
- 인사이트는 '무엇을 발견했는가'보다 '어떻게 활용할 것인가'에 집중하세요.
- 명확하고 간결한 스토리로 설득력 있게 전달하세요.

프로젝트 수행 프로세스



1 문제 정의

- 주제 선정 및 배경 조사
- 문제 정의 및 분석 목표 설정
- 핵심 질문 도출



2 데이터 수집

- 필요 데이터 식별
- 데이터 수집 및 병합
- 데이터 이해 및 탐색



3 데이터 전처리

- 결측치 처리
- 이상치 처리
- 데이터 변환 및 정제



4 탐색적 분석

- 기초 통계 분석
- 시각화 및 패턴 탐색
- 가설 수립



5 심층 분석

- 가설 검증
- 모델링 (선택)
- 결과 해석



6 인사이트 & 제안

- 핵심 인사이트 도출
- 개선/전략 제안
- 의사결정 근거 제시

결과물 구성

구성 항목	세부 내용
분석 보고서	- 문제 정의, 데이터 설명, 분석 과정, 결과 해석, 인사이트 및 제안 포함 (10~15페이지) - 시각화 그래프 및 표 포함
발표 자료	- 핵심 내용 요약 (15~20슬라이드) - 인사이트 중심 스토리텔링 구성
코드 & 데이터	- Python 코드 (주석 포함) - 사용 데이터 또는 전처리 데이터 - README 파일 (실행 방법, 구성 설명)
발표 (팀별)	10분 발표 + 5분 질의응답 - 명확한 인사이트와 실질적 제안 중심

평가 기준 (100점 만점)

평가 항목	배점	평가 내용
문제 정의의 명확성	15점	문제와 목표가 명확하고 구체적인가?
데이터 이해 및 전처리	15점	데이터 특성을 잘 이해하고 적절히 처리했는가?
분석의 적절성	20점	분석 방법이 목표에 적합하고 논리적인가?
결과 해석 및 인사이트	25점	결과 해석이 정확하고 인사이트가 도출되었는가?
의사결정 제안의 실효성	15점	제안이 실질적이고 실행 가능성이 있는가?
보고서 및 발표 완성도	10점	구성이 체계적이고 전달력이 뛰어난가?
합계	100점	

프로젝트 일정 (예시)

- 주제 선정 및 계획 수립 1주차
- 데이터 수집 및 전처리 2주차
- 탐색적 분석 및 가설 수립 3주차
- 심층 분석 및 인사이트 도출 4주차
- 보고서 작성 및 발표 준비 5주차
- 최종 발표 및 제출 6주차

※ 일정은 상황에 따라 조정될 수 있습니다.

최종 결과물 활용



의사결정 근거 제공
데이터 기반으로
객관적 근거 제시



문제 해결 및 개선
실질적인 개선 방안
도출 및 제안



역량 향상
데이터 분석 및
의사결정 역량 강화



포트폴리오 활용
분석 경험을 바탕으로
취업/전학 포트폴리오 강화



미션 1



문제 데이터 찾기

데이터 품질 전문가가 되어
문제가 있는 데이터를 찾아보세요.

찾아야 할 문제 유형



결측값 (Missing Value)

값이 비어 있거나 누락된 데이터



중복 데이터 (Duplicate)

완전히 동일한 행이 반복된 데이터



이상치 (Outlier)

일반적인 범위를 벗어난 데이터



표기 불일치 (Inconsistency)

동일한 값을 다르게 표기한 데이터



오래된 데이터 (Old Data)

기간이 오래되어 최신성이 떨어진 데이터

제공 데이터

student_survey_dirty.csv (더티 데이터 : 일부에 문제 포함)

학번	학과	성별	만족도(1-5)	출석률(%)	설문일자
2025001	컴퓨터공학	M	5	95	2025-03-10
2025002	전자공학	F	4	88	2025-03-11
2025003	컴퓨터공학	M	3	90	2025-03-12
...	...	...	...	...	...
2025014	전자공학	F	4	-5	2023-01-05

※ 위 데이터는 일부만 보여주며, 실제 파일에는 더 많은 문제가 포함되어 있습니다.

미션 수행을 위한 기본 코드

```

1 import pandas as pd
2
3 df = pd.read_csv('student_survey_dirty.csv')
4
5 # 1. 데이터 구조 확인
6 df.info()
7
8 # 2. 결측값 확인
9 df.isnull().sum()
10
11 # 3. 중복 데이터 확인
12 df.duplicated().sum()
13
14 # 4. 이상치 확인을 위한 기초 통계
15 df.describe()
```



Tip

- 위 코드를 실행하여 문제를 찾아보세요.
- 필요하면 추가 코드를 작성해도 좋습니다.
- 시각화를 활용하면 더 쉽게 발견할 수 있습니다.

문제 발견 체크리스트

문제 유형	발견 여부 (✓ 표시)	발견 내용 요약 (개수, 예시 등)
? 결측값	☐	
📄 중복값	☐	
📈 이상치	☐	
A=A 표기 불일치	☐	
📅 오래된 데이터	☐	



Challenge

몇 개의 문제가 숨어 있을까요?

모든 문제를 찾아보세요!



미션 목표

데이터를 분석하기 전에
문제 데이터를 먼저 발견한다!



문제 발견



데이터 정제



품질 평가



좋은 데이터 확보

핵심 포인트

정확한 분석과 의사결정을 위해서는
깨끗하고 신뢰할 수 있는 데이터가
필수입니다.



미션 2



데이터 정제하기

문제가 있는 데이터를 정제하여
분석에 사용할 수 있는 깨끗한 데이터로
만들어보세요.



미션 목표

- ✓ 결측값 처리
- ✓ 중복 데이터 제거
- ✓ 오류/이상 데이터 수정
- ✓ 표기 불일치 통일



Tip

- 데이터 정제 순서를 체계적으로 정하세요.
- 원본 데이터를 보존하고 새로운 데이터프레임을 만드는 것이 안전합니다.
- 변경 전/후를 비교하여 결과를 확인하세요.

제공 데이터



student_survey_dirty.csv

(문제가 있는 원본 데이터)

학번	학과	성별	만족도(1-5)	출석률(%)	설문일자
2025001	컴퓨터공학	M	5	95	2025-03-10
2025002	전자공학	F	4	88	2025-03-11
2025003	컴퓨터공학	M	3	90	2025-03-12
2025003	컴퓨터공학	m	3	90	2025-03-12
2025005	산업공학	F	4	85	2025/03/13
...	...	...	...	...	...
2025014	전자공학	F	4	-5	2023-01-05

※ 실제 파일에는 더 많은 문제가 포함되어 있습니다.

정제 작업 가이드

1	결측값 처리	결측값을 적절한 값으로 채우거나 삭제합니다.
2	중복 데이터 제거	완전히 동일한 행(중복 데이터)을 제거합니다.
3	오류/이상 데이터 수정	범위를 벗어난 값(예: 출석률 -5)을 정상 값으로 수정합니다.
4	표기 불일치 통일	대소문자, 날짜 형식 등 일관되지 않은 표기를 통일합니다.
5	데이터 타입 정리	각 열의 데이터 타입을 적절하게 변경합니다.

정제에 사용할 주요 코드 예시

1. 결측값 처리

```
# 결측값 개수 확인
df.isnull().sum()

# 평균으로 채우기 (숫자형 열)
df['출석률(%)'] = df['출석률(%)'].fillna(
df['출석률(%)'].mean())

# 특정 값으로 채우기
df.fillna('Unknown', inplace=True)
```

2. 중복 데이터 제거

```
# 중복 개수 확인
df.duplicated().sum()

# 중복 제거
# (첫 번째 행만 남기기)
df = df.drop_duplicates()

# 모든 열을 기준으로 중복 제거
```

3. 오류/이상 데이터 수정

```
# 출석률 범위 수정 (0~100)
df.loc(df['출석률(%)'] < 0, '출석률(%)') = 0
df.loc(df['출석률(%)'] > 100, '출석률(%)') = 100

# 만족도 범위 수정 (1~5)
df.loc(df['만족도(1-5)'] < 1, '만족도(1-5)') = 1
df.loc(df['만족도(1-5)'] > 5, '만족도(1-5)') = 5
```

4. 표기 불일치 통일

```
# 성별 대소문자 통일
df['성별'] = df['성별'].str.upper()

# 날짜 형식 통일
df['설문일자'] = pd.to_datetime(
df['설문일자'], errors='coerce')

df['설문일자'] = df['설문일자'].dt.strftime('%Y-%m-%d')
```

5. 데이터 타입 정리

```
# 데이터 타입 확인
df.dtypes

# 타입 변환
df['만족도(1-5)'] = df['만족도(1-5)'].astype(int)
df['출석률(%)'] = df['출석률(%)'].astype(float)
```

정제 전/후 비교 예시

정제 전 (일부)

학번	성별	만족도(1-5)	출석률(%)	설문일자
2025003	m	3	90	2025-03-12
2025014	F	4	-5	2023-01-05
2025005	F	4	85	2025/03/13
2025003	M	3	90	2025-03-12



정제 후 (일부)

학번	성별	만족도(1-5)	출석률(%)	설문일자
2025003	M	3	90.0	2025-03-12
2025014	F	4	0.0	2023-01-05
2025005	F	4	85.0	2025-03-13
(중복 제거)	-	-	-	-



정제 완료 확인 체크리스트

- ☐ 결측값이 모두 처리되었나요? (df.isnull().sum().sum() == 0)
- ☐ 중복 데이터가 모두 제거되었나요? (df.duplicated().sum() == 0)
- ☐ 이상치가 정상 범위로 수정되었나요? (출석률: 0~100, 만족도: 1~5)
- ☐ 표기 불일치가 통일되었나요? (성별: M/F, 날짜 형식: YYYY-MM-DD)
- ☐ 데이터 타입이 적절하게 설정되었나요? (정수/실수/날짜 등)



Challenge

정제 전과 후의 데이터를
비교하여 얼마나 개선되었는지
적절 확인해보세요!



기억하세요!

깨끗한 데이터가 정확한 분석과 올바른 의사결정의 시작입니다.





미션 3



의사결정 인사이트 도출

정제된 데이터를 기반으로 데이터를 해석하고, 최적의 의사결정안을 제안해 보세요.



상황

학생 만족도 향상을 위한 예산은

100만원

모든 문제를 동시에 해결할 수 없습니다.

1. 데이터 요약 (정제 후)

전체 평균 만족도 (5점 만점)	3.8
출석률 80% 이상 학생 평균 만족도	4.4
출석률 80% 미만 학생 평균 만족도	2.9
학과별 평균 만족도 (상위/하위)	
• 상위 : 컴퓨터공학과	4.2
• 하위 : 전자공학과	3.6
성별 평균 만족도	
• 남학생 평균	3.5
• 여학생 평균	4.0
전체 평균 출석률	76.5%



핵심 관찰 포인트

- 출석률이 높을수록 만족도가 높다.
- 컴퓨터공학과 만족도가 가장 높고, 전자공학과가 낮다.
- 남학생 만족도가 상대적으로 낮다.

2. 의사결정 과제



예산 100만원을 어디에 투입할 것인가?

가장 효과가 클 것으로 예상되는 한 가지를 선택하세요.

1



출석률 향상 프로그램

출석률이 낮은 학생을 위한
출석 관리 및 학습 지원

2



전자공학과 지원

만족도가 낮은 전자공학과
맞춤형 지원 프로그램

3



남학생 지원 프로그램

남학생 만족도 향상을 위한
상담 및 멘토링 프로그램

4



강의 콘텐츠 개선

전체 학생 대상 강의 품질
및 콘텐츠 개선

질문 1 왜 그 선택이 최선이라고 생각하는가?

- ☐ 데이터에서 어떤 사실을 확인했나요?
- ☐ 그 사실이 왜 중요한가요?
- ☐ 선택한 정책이 어떤 변화를 만들 수 있나요?

TIP

수치, 비교, 변화 가능성 등을
데이터 기반으로 설명하세요.

질문 2 총장에게 보고한다면 어떤 메시지로 제안할 것인가?

TIP

핵심 내용을 한 문장으로 간결하게!
(예: "출석률 향상에 투자하면 전체 만족도가 가장 크게 향상됩니다.")

3. 인사이트 작성 공간



나의 의사결정 제안

선택한 항목 : ① / ② / ③ / ④ (번호 기입)

제안 이유 (데이터 근거 포함)



예상되는 효과

- 단기 효과 : _____
- _____
- 장기 효과 : _____
- _____



Challenge!

정답은 없습니다!

하지만 데이터가 근거가 되어야 합니다.

분석 → 인사이트
→ 의사결정 과정문제 발견
(12번 미션)데이터 정제
(13번 미션)분석 및 인사이트 도출
(14번 미션)데이터 품질 평가
(15번 미션)실습 마무리
(16번 미션)

★ 기억하세요!

데이터를 해석하고, 인사이트를 도출하는 것이
진짜 데이터 활용의 핵심입니다.



미션 3



데이터 품질 평가

정제된 데이터는
얼마나 좋은 데이터를 되었을까요?



미션 목표

데이터 품질 평가 기준을 이해하고,
정제 전·후 데이터를 비교하여
품질 개선 정도를 평가합니다.



평가 방법

- ✓ 각 항목을 1~5점으로 평가합니다.
- ✓ 점수가 높을수록 품질이 우수합니다.
- ✓ 품별로 평가 근거를 작성해봅시다.

※ 1점: 매우 낮음 / 3점: 보통 / 5점: 매우 높음

1. 데이터 품질 평가 기준

평가 항목	설명
정확성 (Accuracy)	값이 실제 상황이나 정의에 맞게 올바르게 입력되었는가?
완전성 (Completeness)	누락된 값 없이 필요한 정보가 충분히 존재하는가?
일관성 (Consistency)	동일한 값이 같은 형식과 규칙으로 표현되는가?
최신성 (Timeliness)	데이터가 현재 시점에서도 유효하고 최신 상태인가?
관련성 (Relevance)	분석 목적과 관련 있는 데이터로 구성되어 있는가?

2. 품질 점수 평가표 (1~5점)

평가 항목	정제 전 (문제 데이터)	정제 후 (정제된 데이터)
정확성	2점	5점
완전성	3점	5점
일관성	2점	5점
최신성	3점	5점
관련성	5점	5점
총점 (25점 만점)	15점	25점

※ 예시 점수입니다. 실제 평가는 여러분 팀의 데이터로 진행하세요.

3. 평가 결과



정제 전 품질 점수

15 / 25점



정제 후 품질 점수

25 / 25점



핵심 인사이트

데이터 정제는 단순한 수정 작업이 아니다.

분석 결과의 신뢰도를 높이는
가장 중요한 과정이다.

4. 학생 활동



우리 팀의 데이터 품질 점수는 몇 점인가?

- 각 항목별로 점수를 부여하고 평가 근거를 작성해보세요.
- 정제 전·후 데이터를 비교하여 품질 개선 정도를 확인해봅시다.

평가 근거 예시

- ✓ 결측값이 대부분 제거되어 완전성이 높아졌다.
- ✓ 중복값 제거로 정확성과 일관성이 개선되었다.
- ✓ 오래된 날짜 형식 통일로 최신성이 확보되었다.
- ...

데이터 품질 개선 프로세스

문제 발견
(미션 1)데이터 정제
(미션 2)품질 평가
(미션 3)분석 수행
(미션 4)의사결정
(실무 적용)



실습 마무리



좋은 데이터가 좋은 의사결정을 만든다!

데이터 품질을 관리하는 능력이 데이터 기반 의사결정의 시작입니다.

1. 우리가 수행한 과정

- 문제 데이터 찾기**
결측값, 중복값, 이상치, 표기 불일치 등 발견
- 데이터 정제하기**
결측값 처리, 중복 제거, 이상치 수정, 표기 통일
- 데이터 품질 평가**
정확성, 완전성, 일관성, 최신성, 관련성 평가
- 데이터 분석**
정제된 데이터를 기반으로 시각화, 집계, 패턴 분석
- 의사결정 도출**
분석 결과를 바탕으로 실질적인 인사이트 도출

2. 데이터 정제 전·후 비교

항목	정제 전 (Before)	정제 후 (After)
결측값	존재	→ 제거
중복 데이터	존재	→ 제거
이상치	존재	→ 수정
표기 불일치	존재	→ 통일
데이터 품질	낮음 ★☆☆☆☆	→ 높음 ★★★★★



좋은 데이터



좋은 분석



좋은 의사결정



좋은 성과

데이터의 품질이 결과의 품질을 결정합니다!

3. 최종 성과

- 신뢰 가능한 데이터 확보**
문제 데이터를 제거하고 일관성 있는 데이터를 확보했습니다.
- 분석 결과의 정확성 향상**
정확한 데이터가 분석 결과의 신뢰도를 높입니다.
- 의사결정 근거 확보**
데이터 기반의 객관적 근거로 더 나은 의사결정을 할 수 있습니다.
- 데이터 기반 사고 경험**
문제 인식 → 해결 → 평가 과정을 통해 데이터 리터러시가 향상되었습니다.

실습 핵심 메시지



분석 기술보다 먼저 확인해야 할 것은
데이터 품질이다.

★ 기억하세요!



데이터를 분석하기 전에
데이터가 믿을 만한지 먼저 확인하자.
좋은 데이터가 좋은 결과를 만든다!

다음 강의 예고



4강

데이터 수집과 데이터 전처리

- CSV 데이터 이해
- 데이터 변환
- 결측값 처리 심화
- 실전 데이터 정제

