



12강

결정하기 전에, 작은 실험을 할 수 있을까?

상관관계와 인과관계 · 실험집단과 비교집단 · A/B 테스트 · 실험 지표

오늘 배울 것



상관관계와 인과관계 구분하기

두 변수가 함께 움직인다고 해서, 하나가 다른 하나의 원인이라 할 수는 없다는 것을 사례로 이해한다.



실험집단과 비교집단으로 인과 확인하기

무작위로 나눈 두 집단을 비교하면, 관찰만으로는 알 수 없던 진짜 효과를 확인할 수 있다.



A/B 테스트의 원리와 사례

웹·앱에서 두 버전을 동시에 실험해 어느 쪽이 더 나은지 데이터로 판단하는 방법을 익힌다.



실험 지표 설계하기

무엇이 좋아졌다고 볼 것인지(주 지표), 무엇이 나빠지면 안 되는지(가드레일 지표)를 구분해서 설계한다.

지금까지 우리는 무엇을 배웠나

9강

불확실한 상황에서 확률로 판단하기

10강

비용과 효과를 함께 비교하기

11강

판단이 흔들리는 6가지 함정을 알기

그런데, 결정을 실행하기 전에 미리 확인해볼 수는 없을까? 오늘은 '작게 실험해서 미리 확인하는 법'을 배웁니다.



오늘의 질문: 판단이 아니라, 데이터로 미리 검증할 수는 없을까?

상관관계와 인과관계는 다르다

상관관계(correlation) = 두 변수가 함께 움직이는 관계. **인과관계(causation)** = 한 변수를 바꾸면 다른 변수가 실제로 바뀌는 관계.

두 그래프가 함께 움직이면 우리는 본능적으로 '하나가 다른 하나를 일으켰다'고 생각한다. 하지만 실제로는 다음 셋 중 하나인 경우가 많다 — 제3의 원인(교란변수)이 둘 다를 움직였거나, 원인과 결과가 뒤바뀌었거나(역인과관계), 그냥 우연이었거나. 다음 두 슬라이드에서 각각을 살펴보자.



핵심 질문 하나: '이 변수를 내가 직접 바꿔도 저 결과가 바뀔까?' — 그렇다면 인과, 아니라면 상관에 머무는 것이다.

고전 사례: 아이스크림과 익사 사고



관찰된 상관관계

월별 아이스크림 판매량이 많은 달일수록, 그 달의 익사 사고 건수도 함께 늘어난다 — 실제 통계에서도 나타나 는 잘 알려진 상관관계다.



진짜 원인: 숨은 변수

아이스크림을 먹어서 물에 빠지는 게 아니다. 더운 날씨가 아이스크림 소비도, 물놀이(그래서 익사 위험)도 함께 늘린다 — 이 '더위'가 교란변수(confounder)다.



두 변수가 원인-결과가 아니라, 제3의 변수가 둘 다를 움직이는 경우 — 상관관계 착시의 가장 흔한 형태.

제품 사례: 다크모드와 앱 사용시간



관찰된 상관관계

다크모드 사용자가 라이트모드 사용자보다 하루 앱 사용 시간이 훨씬 길다 — '다크모드가 몰입을 돕는다'는 결론을 내리기 쉽다.



숨은 변수: 파워 유저

실제로는 원래 앱을 많이 쓰는 '파워 유저'일수록 다크모드를 선호하는 경향이 있다. 다크모드가 사용시간을 늘리게 아니라, 많이 쓰는 사람이 다크모드를 고른 것일 수 있다.



다음 시간 실습에서, 이 착시를 실제 데이터로 직접 확인해 봅니다.

상관관계가 인과관계로 착각되는 3가지 이유



① 교란변수

제3의 변수가 두 변수를 동시에 움직인다. (예: 더워 → 아이스크림·익사 둘 다 증가)



② 역인과관계

원인과 결과가 뒤바뀐 것일 수 있다. (예: 장애가 잦아서 모니터링 도구를 더 쓰는 것)



③ 우연(chance)

표본이 우연히 그렇게 나온, 실제로는 아무 관계 없는 상관관계일 수 있다.



그래서 상관관계만으로는 '원인'을 말할 수 없다 — 그럼 어떻게 인과를 확인할까?

실험집단과 비교집단으로 인과를 확인한다

실험집단(treatment group) = 새 조치를 적용하는 집단. **비교집단(control group)** = 기존 그대로 두는 집단.



관찰 연구 (observational)

이미 있는 데이터를 그냥 나눠서 비교한다. (예: '다크모드를 쓰는 사람들' vs '안 쓰는 사람들') → 누가 어느 쪽을 골랐는지가 이미 편향되어 있어, 교란변수 문제가 그대로 남는다.



실험 연구 (controlled experiment)

사용자를 무작위로 두 집단에 배정한 뒤 비교한다. (예: 절반은 무작위로 다크모드, 절반은 라이트모드) → 배정을 무작위로 하면, 교란변수까지 두 집단에서 평균적으로 비슷해진다.



핵심은 '무작위 배정' — 배정을 사람이 고르게 두면, 교란변수가 다시 끼어든다.

왜 하필 '무작위' 배정이어야 할까



무작위 배정 없이 나누면

'다크모드를 원하는 사람만 바꾸게' 허용하면, 여전히 파워 유저가 다크모드 쪽에 더 많이 몰릴 수 있다. 두 집단의 차이를 봐도, 그게 다크모드 때문인지 파워 유저 때문인지 구분이 안 된다.



동전 던지듯 무작위로 나누면


각 사용자를 동전 던지듯 무작위로 절반씩 배정하면, 두 집단은 파워 유저 비율마저 평균적으로 비슷해진다. 이제 차이가 난다면, 그건 우리가 알든 모르든 다크모드 자체의 효과일 가능성이 높다.



무작위 배정은 우리가 알지도 못하는 교란변수까지 '평균적으로' 같게 만들어주는 유일한 방법이다.

A/B 테스트란 무엇인가

A/B 테스트 = 사용자를 무작위로 A(기존 버전)와 B(새 버전) 두 그룹으로 나누고, 동시에 노출시켜 행동 데이터로 비교하는 실험 — 웹·앱에서 가장 널리 쓰이는 실험집단·비교집단 설계다.



여러분이 지금 쓰는 거의 모든 앱은, 지금 이 순간도 어떤 A/B 테스트 안에 들어 있을 가능성이 높다.

사례 · 링크 색깔 하나로 연 2억 달러



구글, 검색 결과 링크의 파란색 실험 (2009)

2009년 구글 디자인팀은 검색 결과 링크의 파란색 색조를 두고, 디자이너의 직관 대신 실험을 택했다. 여러 파란색 후보를 실제 사용자에게 무작위로 노출시켜 클릭률을 비교한 결과, 팀이 애초에 선호하던 색과는 다른 색조가 더 높은 클릭률을 기록했다. 이 결정 하나가 연간 약 2억 달러의 추가 광고 수익으로 이어졌다고 알려져 있다.



디자이너의 취향이 아니라, 무작위로 나뉜 두 집단의 실제 클릭 데이터가 승자를 정했다.

사례 · 실험 하나로 6,000만 달러를 더 모금하다



오바마 2008 대선 캠페인, 24가지 조합 실험

2008년 오바마 대선 캠프는 웹사이트 첫 화면에서 버튼 문구 4종과 이미지·영상 6종, 총 24가지 조합을 무작위로 실험했다. 가장 성과가 좋았던 조합('더 알아보기' 버튼 + 가족 사진)은 가입률이 기존 8.26%에서 11.6%로, 약 40.6% 높아졌다. 이 차이는 약 288만 건의 추가 이메일 가입으로 이어졌고, 가입자 한 명당 평균 21달러를 기부한 것을 감안하면 약 6,000만 달러의 추가 모금 효과로 추정된다.



팀이 선호했던 건 영상이었지만, 실험 결과 모든 영상이 사진보다 낮은 성과를 보였다 — 직관과 실험이 다르면, 실험이 이긴다.

사례 · 우선순위 낮았던 아이디어, 연 1억 달러였다

Ad

마이크로소프트 Bing, 광고 제목 표시 방식 실험

Bing의 한 엔지니어는 검색 결과에서 광고 제목이 표시되는 방식을 바꾸자는 아이디어를 냈다. 구현에는 며칠이면 충분했지만, 담당자들은 이 아이디어의 우선순위를 6개월 동안 낮게 매겨두었다. 마침내 실험을 돌려보니, 사용자 경험 지표에는 부정적 변화가 없으면서 매출은 12% 증가했다 — 미국에서만 연간 1억 달러 이상의 효과로 추정됐다.



직관으로는 '작아 보이는' 아이디어였다 — 실험하지 않았다면 6개월이 아니라 영원히 묻혔을 것이다.

실험 지표: 주 지표와 가드레일 지표

주 지표(primary metric) = 이번 실험으로 개선하려는 핵심 목표. **가드레일 지표(guardrail metric)** = 좋아져도 절대 나빠지면 안 되는 안전 지표.



주 지표 예시

전환율(conversion rate), 클릭률, 가입률, 매출 — '이번 실험이 성공했는가'를 판단하는 단 하나의 핵심 숫자.



가드레일 지표 예시

오류 발생률, 페이지 로딩 실패율, 구독 해지율, 이탈률 — 주 지표가 좋아져도 이 지표가 나빠지면 배포를 재고해야 한다.



주 지표만 보고 배포하면 '눈앞의 승리가 나중의 손해'가 될 수 있다 — 10강의 단기 효과·장기 효과가 여기서도 그대로 적용된다.

실험을 설계할 때 놓치기 쉬운 4가지



표본 크기는 충분한가

표본이 너무 작으면, 진짜 차이가 없어도 우연히 유의해 보이거나, 진짜 차이가 있어도 놓칠 수 있다.



실행 기간은 충분한가

요일별·주별 패턴을 다 담을 만큼 돌려야 한다. 너무 일찍 멈추면 결과가 왜곡된다.



신기성 효과(novelty effect)를 조심하라

새 버전이라 낯설어서 반응이 다를 수 있다 — 초반 반응만 보고 성급히 결론 내지 않는다.



표본비율불일치(SRM)를 확인하라

무작위로 나뉘었다면 두 집단 크기가 의도한 비율과 비슷해야 한다. 크게 어긋나면 실험 자체에 버그가 있다는 신호다

오늘 배운 네 가지, 한눈에 정리

개념	한 줄 정의	핵심 포인트
상관관계·인과관계	함께 움직인다고 원인은 아니다	교란변수·역인과·우연을 의심하라
실험집단·비교집단	무작위로 나눠 비교해야 인과를 안다	무작위 배정이 핵심, 자기선택은 함정
A/B 테스트	두 버전을 동시에 실험해 비교한다	직관과 결과가 다르면 실험이 이긴다
실험 지표	주 지표와 가드레일 지표를 함께 본다	눈앞의 승리가 나중의 손해일 수 있다

다음 실습: 상관을 깨고, 실험을 분석하자

오늘 배운 개념 네 가지를 다음 시간엔 파이썬으로 직접 확인합니다.



1. 상관관계 착시 깨기

다크모드 데이터를 파워 유저 여부로 나눠서, 진짜 효과가 얼마나 남는지 직접 확인



2. A/B 테스트 분석하기

전환율을 카이제곱 검정으로 비교하고, 가드레일 지표(오류율)까지 함께 점검



3. 몬테카를로로 표본 크기 이해하기

9~11강의 random 모듈로, 표본이 작으면 왜 결과를 믿기 어려운지 시뮬레이션



준비물은 **pandas, scipy.stats, random** — 9~11강에서 배운 그대로면 충분합니다!

오늘의 핵심 정리

- ✓ 상관관계는 인과관계가 아니다 — 교란변수·역인과관계·우연을 먼저 의심하라
- ✓ 실험집단과 비교집단을 무작위로 나눠야, 관찰만으로는 알 수 없던 인과를 확인한다
- ✓ A/B 테스트: 구글·오바마 캠페인·Bing 사례처럼, 직관과 결과가 다르면 실험이 이긴다
- ✓ 실험 지표는 둘이다 — 주 지표(성공 여부)와 가드레일 지표(부작용 감시)를 함께 본다



다음 시간 · 실습편 예고

다크모드 데이터로 상관관계 착시 깨기, A/B 테스트 통계 검정, 표본 크기 몬테카를로까지.



12강 실습

상관을 깨고, 실험을 읽는 법

다크모드 상관관계 착시 깨기 · A/B 테스트 카이제곱 검정 · 몬테카를로 표본크기 — 실험을 데이터로 검증하기

오늘 만들 것 — 세 개의 답



상관관계 착시, 수치로 깨기

다크모드와 사용시간의 23.1분 차이 중 진짜 효과가 얼마나 되는지 증화분석으로 확인한다.



A/B 테스트, 통계로 검증하기

전환율 차이가 우연인지 카이제곱 검정으로 확인하고, 가드레일 지표까지 함께 점검한다.



몬테카를로로 표본 크기 이해하기

표본이 작으면 왜 결과를 믿기 어려운지, 반복 시뮬레이션으로 직접 확인한다.

오늘의 최종 산출물 “다크모드의 진짜 효과는 약 3~7분, A/B 테스트 결과는 유의($p=0.028$)하지만 표본을 늘리면 더 믿을 수 있다.” — 이 문장을 직접 계산합니다.

오늘의 진행 —

10분

도입 · 세 가지 데이터 소개

Colab 접속, 이론 복습, 오늘 쓸 CSV 세 개 미리보기

25분

PART 1 · 상관관계 착시 깨기

그룹 평균 → 그래프+t검정 → 층화분석 → 해석

25분

PART 2 · A/B 테스트 분석

전환율 → 시각화 → 카이제곱검정 → 가드레일 체크

10분

휴식

30분

PART 3 · 몬테카를로 표본크기

우연히 유의? → 해석 → 검정력 계산 → 곡선 → 결론

15분

PART 4 · 미니 챌린지

이메일 제목 A/B 테스트 — 주지표·가드레일 함께 판단

5분

정리 · 과제 안내

시작 전 점검 — 5분 안에 끝내기



환경 준비

- colab.research.google.com 접속 → 새 노트북
- pandas, scipy, matplotlib 모두 기본 제공
- 오늘 쓸 CSV 3개를 미리 업로드해 둘 것



12강 이론 기억 소환 (체크!)

- 상관관계 $\neq$ 인과관계 — 교란변수를 의심하라
- 실험집단·비교집단은 무작위 배정이 핵심
- A/B 테스트 = 두 버전을 동시에 실험해 비교



오늘의 규칙: 착시인지 진짜인지는 항상 증화분석과 통계검정으로 확인한다.

오늘 쓸 데이터 3종 미리보기



darkmode_engagement.csv

사용자 200명 — 테마(다크/라이트),
파워유저 여부, 일일 앱 사용시간



ab_test_results.csv

사용자 2,000명 — A/B 그룹, 전환 여
부, 오류 발생 여부(가드레일)



email_subject_test.csv

구독자 1,600명 — 이메일 제목 A/B,
오픈 여부, 구독 해지 여부 (PART4에
서 사용)



세 파일 모두 Colab 좌측 파일 탭에 업로드해 두세요 — 파트가 시작될 때마다 하나씩 불러옵니다.

PART 1

25분

상관관계 착시 깨기

다크모드와 사용시간의 상관관계 중, 진짜 인과 효과가 얼마나 되는지 데이터로 확인한다

- 1 데이터 불러와 그룹 평균 비교하기 (naive)
- 2 그래프+t검정으로 '차이가 진짜'임을 확인하기
- 3 파워 유저 여부로 층화분석하기
- 4 해석: 상관관계 중 진짜 인과는 얼마인가

데이터 불러와 그룹 평균 비교하기 (naive)

```
import pandas as pd

df = pd.read_csv("darkmode_engagement.csv")
print(df.groupby("theme")
      ["daily_minutes"].mean())
```

load_theme.py

실행 결과

theme	
dark	67.6
light	44.6

23.1분 차이!

다크모드 사용자가 라이트모드 사용자보다 하루 평균 23.1분 더 오래 앱을 쓴다.



12강 이론에서 본 그 상관관계 — 이제 우리 데이터로 재현했다. 그런데 이게 다크모드 '때문'일까?

그래프로 보고, t검정으로 확인하기

```
import matplotlib.pyplot as plt
from scipy import stats

dark = df[df.theme=="dark"].daily_minutes
light = df[df.theme=="light"].daily_minutes
plt.bar(["dark", "light"],
        [dark.mean(), light.mean()])
t, p = stats.ttest_ind(dark, light)
```

plot_ttest.py

실행 결과

t = 9.63

p = 3.07e-18

통계적으로 명백한 차이

p값이 사실상 0 — 이 차이가 우연일 확률은 거의 없다.



p값은 '차이가 우연이 아니다'를 말해줄 뿐 — '원인이 다크모드다'는 아직 말해주지 않는다.

파워 유저 여부로 층화분석하기



stratify.py

```
print(df.groupby(["power_user", "theme"])
      ["daily_minutes"].mean())
```

실행 결과

	power_user	theme	
0	dark	43.0	
0	light	39.7	
1	dark	79.6	
1	light	72.7	

gap이 23.1 → 3~7분으로!



같은 파워유저 안에서 비교하면, 다크모드-라이트모드 차이가 훨씬 작아진다 — **groupby**에 리스트를 넣으면 여러 기준으로 동시에 나눌 수 있다.

23.1분 차이의 정체

만약 다크모드가 유일한 원인이라면

파워유저로 나뉘서 봐도 여전히 23분 안팎의 차이가 유지되어야 한다.

실제로는

파워유저 안에서는 6.9분, 일반유저 안에서는 3.3분 차이로 크게 줄어든다 — 23.1분 중 상당 부분은 '파워유저가 다크모드를 더 선호한다'는 교란변수 때문이었다.

우리는 방금 이론(12강)의 주장을 직접 확인했다. 상관관계(23.1분 차이)는 진짜였지만, 다크모드의 순수한 효과는 그중 일부(약 3~7분)뿐이었다.

내 손으로 확인하기 ① (7분)

M1

각 그룹의 파워유저 비율을 계산해 보자 — 다크모드 쪽이 더 높을까?

힌트: `df.groupby("theme")["power_user"].mean()`

M2

라이트모드 사용자만 골라 `daily_minutes` 히스토그램을 그려보자

힌트: `plt.hist(df[df.theme=="light"].daily_minutes, bins=10)`

M3

`daily_minutes`의 표준편차도 그룹별로 계산해 보자

힌트: `df.groupby("theme")["daily_minutes"].std()`

다 끝난 사람은: `power_user`로 나누지 않고 `theme`만으로 다시 t검정을 돌려, STEP2 결과와 비교해 볼 것

PART 2

25분

A/B 테스트, 통계로 검증하기

전환율 차이가 우연인지 통계로 확인하고, 가드레일 지표까지 함께 점검한다

1 데이터 불러와 그룹별 전환율 계산하기

2 그래프로 보고, 상대 lift 계산하기

3 카이제곱 검정으로 유의성 확인하기

4 가드레일 지표(오류율) 점검하기

데이터 불러와 그룹별 전환율 계산하기

```
load_ab.py

df2 = pd.read_csv("ab_test_results.csv")
print(df2.groupby("group")
      ["converted"].mean())
```

실행 결과

group	
control	0.096
treatment	0.127

9.6% vs 12.7%

새 버전(treatment)의 전환율이 기존(control)보다 눈에 띄게 높다.




각 그룹 1,000명씩 무작위 배정 — 12강 이론에서 배운 실험집단·비교집단 설계 그대로다.

그래프로 보고, 상대 lift 계산하기

```
plot_lift.py

rates = df2.groupby("group")["converted"].mean()
plt.bar(rates.index, rates.values,
        color=["#0891B2", "#E8506E"])

lift = (rates["treatment"] - rates["control"])
      / rates["control"]
print("상대 lift:", round(lift*100,1), "%")
```



상대 lift는 +32.3% — 그런데 표본이 1,000명씩인데, 이 차이는 우연이 아닐까?

카이제곱 검정으로 유의성 확인하기

```
chisq_ab.py

from scipy.stats import chi2_contingency

c = df2[df2.group=="control"].converted.sum()
t = df2[df2.group=="treatment"].converted.sum()
table = [[c, 1000-c], [t, 1000-t]]
chi2, p, dof, exp = chi2_contingency(table)
print("chi2 =", round(chi2,2), " p =", round(p,4))
```

실행 결과

```
chi2 = 4.85
p = 0.0276
```

$p < 0.05 \rightarrow$ 통계적으로 유의

전환율 차이가 우연일 확률은 약 2.8% — 5% 기준을 통과한다.



카이제곱 검정: 두 그룹의 '비율' 차이가 우연인지 판단하는 통계 도구 — t검정의 비율 버전이다.

가드레일 지표(오류율) 점검하기

```
guardrail.py

print(df2.groupby("group")
      ["error_occurred"].mean())

ec = df2[df2.group=="control"].error_occurred.sum()
et = df2[df2.group=="treatment"].error_occurred.sum()
table2 = [[ec, 1000-ec], [et, 1000-et]]
chi2_contingency(table2)
```

실행 결과

```
control      0.035
treatment    0.035
chi2=0.0    p=1.0
```

가드레일 이상 없음

오류율은 두 그룹이 완전히 동일 — 새 버전
이 전환율은 높이면서 부작용은 없다.



주 지표(전환율)만 보고 배포하면 안 된다 — 가드레일 지표(오류율)까지 함께 확인해야 안심하고 배포할 수 있다.

그런데, 이 결론은 얼마나 믿을 수 있을까?

전환율 +32.3%($p=0.028$, 유의), 오류율 변화 없음($p=1.0$) — 지금까지의 결과만 보면 '배포 권장'이라고 결론 내릴 수 있다.

그런데 표본이 1,000명씩뿐인데, 이 정도로 확신해도 될까? 다음 파트에서 몬테카를로로 직접 확인해 봅시다.



표본 크기가 결론의 신뢰도에 미치는 영향 — 오늘의 하이라이트, 파트 3에서 이어집니다.

내 손으로 확인하기 ② (6분)

M1

control과 treatment의 표본을 각각 앞 100명씩만 잘라서 같은 카이제곱검정을 돌려보자

힌트: `df2[df2.group=="control"].head(100)` — *p값이 어떻게 바뀌는가?*

M2

오류율 대신 '재방문 여부' 같은 새로운 가드레일 지표가 있다면 무엇을 점검하고 싶은지 적어보자

힌트: 이번 실험이 장기적으로 해칠 수 있는 지표를 생각해 보자

M3

상대 lift(32.3%)와 절대 차이(3.1%p)의 차이를 설명해 보자 — 보고서에는 어느 쪽을 써야 할까

힌트: '32% 증가'와 '3.1%p 증가'는 인상이 다르다

다 끝난 사람은: 유의수준을 0.01로 바꿔서 여전히 유의한지 확인해 볼 것



10분 휴식

다음 파트는 오늘의 하이라이트 — 표본 크기가 왜 중요한지 몬테카를로로 확인합니다.

PART 3

30분

몬테카를로로 표본 크기 이해하기

표본이 작으면 왜 결과를 믿기 어려운지, 반복 시뮬레이션으로 확인한다

- 1 표본이 작으면 우연히 유의해 보일 수 있다
- 2 왜 하필 5%일까 — 유의수준의 의미
- 3 진짜 효과가 있을 때, 표본크기별 검정력 계산
- 4 검정력 곡선 시각화 → 우리 실험과 연결
- 5 그래서 몇 명이면 충분한가

표본이 작으면 우연히 유의해 보일 수 있다

진짜로는 두 그룹의 전환율이 완전히 같다(둘 다 10%)고 가정하자. 표본 30명씩을 뽑아 카이제곱검정을 20,000번 반복하면?

sim_false_positive.py

```
import random
from scipy.stats import chi2_contingency

def one_trial(n, p_c, p_t):
    c = sum(1 for _ in range(n) if random.random() < p_c)
    t = sum(1 for _ in range(n) if random.random() < p_t)
    _, p, _, _ = chi2_contingency([[c, n-c], [t, n-t]])
    return p
```



true rate가 둘 다 10%로 같다는 것이 핵심 — 다음 슬라이드에서 20,000번 반복한 결과를 확인한다.

20번에 1번은, 우연히 유의하다고 나온다

```
false_positive_rate.py

hits = sum(1 for _ in range(20000)
           if one_trial(30, 0.10, 0.10) < 0.05)
print("우연히 유의할 확률:", hits/20000)
```

실행 결과

우연히 유의할 확률: 0.0544

약 5.4%

진짜 차이가 전혀 없는데도, $n=30$ 에서는 20번 중 1번 꼴로 '유의하다'는 결과가 우연히 나온다.



이 5.4%는 우연이 아니다 — 유의수준($\alpha=0.05$) 자체가 '진짜 차이가 없어도 5%는 유의하다고 착각하겠다'는 약속이다.

진짜 효과가 있을 때, 검정력 계산하기

이번엔 진짜로 차이가 있다고 하자(파트2와 동일: control 10%, treatment 13%). 표본크기를 바꿔가며 유의한 결과가 나오는 비율(검정력)을 계산한다.


```
power_curve.py

for n in [30, 100, 300, 1000, 2000]:
    hits = sum(1 for _ in range(20000)
               if one_trial(n, 0.10, 0.13) < 0.05)
    print(n, "명 →", hits/20000)    # 검정력(power)
```



검정력(power) = 진짜 효과가 있을 때, 그것을 '유의하다'고 실제로 잡아낼 확률.

검정력 곡선 — 표본이 커질수록 확신도 커진다



n=1,000에서 검정력은 겨우 55.8%

우리가 파트2에서 쓴 표본크기(1,000명씩)가 바로 이 지점이다. 이 실험을 100번 다시 해도, 55번 정도만 '유의하다'는 결과가 나온다는 뜻 — $p=0.028$ 은 real이지만 아슬아슬하다.



표본이 2,000명이면 검정력 84.8% — 같은 실험도 표본이 클수록 결과를 더 믿을 수 있다.

그래서, 몇 명이면 충분할까

표본크기(그룹당)	검정력(power)	해석
30명	6.9%	사실상 동전 던지기 수준
100명	10.1%	여전히 놓칠 확률이 압도적
300명	21.3%	5번 중 1번만 잡아낸다
1,000명	55.8%	우리 실험 — 아슬아슬한 수준
2,000명	84.8%	안심할 수 있는 수준



실험은 '한 번 유의했다'로 끝이 아니다 — 표본 크기가 결론의 신뢰도를 결정한다.

내 손으로 확인하기 ③ (7분)

M1

진짜 효과 크기를 10%→15%로 키우면, $n=100$ 에서 검정력은 몇 %일까? 먼저 예측하고 실행

힌트: `one_trial(100, 0.10, 0.15)`로 20,000번 반복

M2

유의수준을 0.01로 더 엄격하게 하면, $n=30$ 의 false positive rate는 얼마나 될까?

힌트: `hits/20000` 계산에서 조건을 $p<0.01$ 로 바꿔본다

M3

표본을 $n=5,000$ 까지 늘리면 검정력은 몇 %일까? 예측 후 실행해서 확인

힌트: `one_trial(5000, 0.10, 0.13)`

다 끝난 사람은: `N_TRIALS`을 2,000 → 20,000으로 바꿔가며 결과가 얼마나 안정되는지 비교해 볼 것

이메일 제목 A/B 테스트, 배포할까 말까

조별(2~3명)로 15분. email_subject_test.csv — 이메일 제목 A/B 테스트 결과입니다 (control: 기존 제목, treatment: 긴급 문구 추가).

컬럼 안내

- group — control / treatment
- opened — 이메일을 열었는가 (주 지표)
- unsubscribed — 구독을 해지했는가 (가드레일 지표)

답해야 할 것

- 오픈율 차이가 유의한지 카이제곱 검정으로 확인
- 구독 해지율(가드레일)도 같은 방식으로 확인
- 배포할지 말지, 권고안 한 문장



발표 형식: “주 지표는 ○○, 가드레일 지표는 ○○ — 그래서 배포를 이렇게 결정해야 합니다.”

발표가 끝난 뒤에 함께 확인

```
df3 = pd.read_csv("email_subject_test.csv")
print(df3.groupby("group")["opened"].mean())
print(df3.groupby("group")
      ["unsubscribed"].mean())
# 각각 chi2_contingency로 검정
```

email_ab.py

실행 결과

오픈율	control 0.188
	treatment 0.229
해지율	control 0.009
	treatment 0.038

오픈율 $p=0.042$ (유의) · 해지율 $p=0.0001$ (크게 악화)



권고안: 오픈율(+22%)은 개선됐지만 구독 해지율이 328% 급증 — 배포 보류, 문구 재설계 권장 (10강의 단기 효과·장기 효과, 여기서도 그대로다).

오늘의 핵심 정리

- ✓ 상관관계 착시: 23.1분 차이 중 진짜 다크모드 효과는 총화분석으로 걸러낸 3~7분뿐이었다
- ✓ A/B 테스트: 전환율 +32.3%($p=0.028$)로 유의했고, 가드레일(오류율)도 이상 없었다
- ✓ 표본 크기: $n=1,000$ 의 검정력은 55.8% — 유의함과 확실함은 다르다
- ✓ 실험 지표: 주 지표가 이겨도 가드레일이 나빠지면(이메일 챌린지처럼) 배포를 보류해야 한다



과제 (다음 시간까지)

우리 주변의 '상관관계 뉴스' 하나를 찾아, 교란변수·역인과관계·우연 중 무엇이 숨어 있을지 분석한 한 줄 결론을 담은 노트북을 제출하세요.