

데이터 분석 6강

탐색적 데이터 분석

EDA (Exploratory Data Analysis)

단변량 분석 → 이변량 분석 → 다변량 분석 → 인사이트 도출

 1시간 이론

 pandas + seaborn

 EDA 전 과정

Python 데이터 분석 실무 과정

EDA란? — 오늘의 학습 목표

EDA (Exploratory Data Analysis)

본격 분석 전, 데이터의 구조·분포·관계를 시각화로 탐색하는 과정 — "데이터와 친해지기"



기술통계로 각 변수의 특성 파악 (단변량)



두 변수 사이의 관계 탐색 (이변량)



상관행렬·pairplot으로 전체 구조 조망 (다변량)



EDA 결과로 의미 있는 인사이트 도출

EDA 분석 흐름 & 실습 데이터

1
데이터
로드·확인

2
단변량
분석

3
이변량
분석

4
다변량
분석

5
인사이트
도출

📁 학생 성적 데이터 (student_score.csv)

이름	문자열
성별	M / F
나이	15~19
수학점수	0~100
영어점수	0~100
과학점수	0~100
지역	서울/경기/인천...
학원수강	예/아니오

데이터 로드 코드

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv(
    'student_score.csv',
    encoding='utf-8-sig'
)

print(df.shape)    # (300, 8)
print(df.dtypes)
df.head()
```

💡 300명 · 수치형 3개 · 범주형 5개 — EDA 전 과정 실습에 최적



PART 1

단변량 분석 (Univariate Analysis)

⌚ 약 15분 · 데이터 요약 · 분포 · 기술통계

`describe()` · `value_counts()` · `histplot` · `boxplot`

단변량 분석 ① — 데이터 기본 파악

PART 1

기본 정보 확인

```
df.shape          # (300, 8) 행·열 수
df.dtypes         # 각 열 자료형
df.isnull().sum() # 결측치 개수
df.info()         # 타입 + 결측 한눈에
df.head(5)        # 처음 5행 미리보기
```

범주형 — value_counts()

```
df['성별'].value_counts()
# F      158
# M      142

# 비율 확인
df['성별'].value_counts(normalize=True)
# F      0.53
# M      0.47
```

describe() — 기술통계

```
df.describe()
```

#	수학점수	영어점수
# count	300	300
# mean	68.3	71.2
# std	15.4	12.8
# min	22.0	35.0
# 25%	58.0	63.0
# 50%	69.0	72.0
# 75%	79.0	80.0
# max	100.0	100.0

← 중앙값

mean $\approx$ median

대칭 분포

mean $\gg$ median

오른쪽 꼬리·이상치

std 크다

값이 많이 퍼져 있음

단변량 분석 ② — 분포 시각화

PART 1

histplot — 분포 확인

```
fig, axes = plt.subplots(1, 3, figsize=(15,4))

for i, col in enumerate(['수학점수', '영어점수', '과학점수']):
    sns.histplot(
        data=df, x=col,
        kde=True,      # 분포 곡선 추가
        ax=axes[i]
    )
    axes[i].set_title(f'{col} 분포')

plt.tight_layout()
plt.show()
```

히스토그램 읽기

- 대칭 → 정규분포에 가까움
- 오른쪽 꼬리 → 높은 이상치 주의
- KDE 곡선 → 분포 형태 파악

boxplot — 이상치·퍼짐 확인

```
fig, axes = plt.subplots(1, 3, figsize=(15,4))

for i, col in enumerate(['수학점수', '영어점수', '과학점수']):
    sns.boxplot(
        data=df, y=col,
        ax=axes[i]
    )
    axes[i].set_title(col)

plt.tight_layout()
plt.show()
```

박스플롯 읽기

- 박스 = IQR (25~75%)
- 수염 = 정상 데이터 범위
- 점 = 이상치 후보



PART 2

이변량 분석 (Bivariate Analysis)

🕒 약 20분 · 두 변수 사이의 관계를 탐색합니다

scatter · corr · groupby · boxplot · crosstab

이변량 분석 ① — 수치형 vs 수치형

PART 2

① scatter — 산점도

```
sns.scatterplot(  
    data=df,  
    x='수학점수', y='영어점수',  
    alpha=0.5  
)  
plt.title('수학 vs 영어')  
plt.show()
```

상관계수 해석

$|r| \geq 0.7$

강한 상관

0.4 ~ 0.7

보통 상관

0.2 ~ 0.4

약한 상관

< 0.2

무관

⚠ 상관계수 ≠ 인과관계 / 선형 관계만 측정 / 이상치에 민감

② corr() — 상관계수

```
# 상관행렬  
df[['수학점수', '영어점수', '과학점수']].corr()  
  
# 두 변수 상관계수  
r = df['수학점수'].corr(df['영어점수'])  
print(f'r = {r:.3f}')
```

☆ regplot — 추세선 포함 산점도

```
sns.regplot(  
    data=df,  
    x='수학점수', y='영어점수',  
    line_kws={'color': 'red'}  
)
```


이변량 분석 ② — 범주형 vs 수치형

PART 2

① groupby — 그룹별 통계

```
# 성별 평균 점수
df.groupby('성별')[['수학점수', '영어점수', '과학점수']] \
    .mean().round(1)

# 여러 집계 함수
df.groupby('성별')['수학점수'] \
    .agg(['mean', 'median', 'std'])
```

② boxplot / barplot — 분포 비교

```
# 그룹별 분포 (boxplot)
sns.boxplot(
    data=df, x='성별', y='수학점수'
)

# 그룹별 평균 (barplot)
sns.barplot(
    data=df,
    x='성별', y='수학점수',
    estimator='mean'
)
```

boxplot

분포 전체 (중앙값·IQR·이상치)

barplot

그룹 평균 비교 (오차막대 포함)

violinplot

분포 형태까지 상세히 비교

이변량 분석 ③ — 범주형 vs 범주형

PART 2

```
# ① 교차표 — 빈도
ct = pd.crosstab(df['성별'], df['학원수강'])
print(ct)
#           아니오    예
# 성별
# F             72     86
# M             88     54

# ② 비율 (행 기준)
pd.crosstab(
    df['성별'], df['학원수강'],
    normalize='index'
).round(2)

# ③ 히트맵 시각화
sns.heatmap(
    ct, annot=True, fmt='d', cmap='Blues'
)
plt.title('성별 x 학원수강 교차표')
plt.show()
```

언제 교차표를 쓸까?

두 범주형 변수가 서로 관련이 있는지
확인할 때 사용합니다

```
normalize=False
```

기본 — 빈도 수

```
normalize='index'
```

행(index) 기준 비율

```
normalize='columns'
```

열(column) 기준 비율

```
normalize='all'
```

전체 기준 비율

🔗 분포가 차이 있으면 → 두 변수 관련 가능성
→ 카이제곱 검정으로 통계적 유의성 추가 확인 가능



PART 3

다변량 분석 (Multivariate Analysis)

🕒 약 15분 · 여러 변수 관계를 한 번에 조망합니다

heatmap · pairplot · hue로 그룹 구분


다변량 분석 ① — 상관행렬 히트맵

PART 3

```
# 수치형만 선택 → 상관행렬
corr = df.select_dtypes('number').corr()

plt.figure(figsize=(7, 5))
sns.heatmap(
    corr,
    annot=True,      # 숫자 표시
    fmt='.2f',        # 소수점 2자리
    cmap='coolwarm',  # 빨강↔파랑
    vmin=-1, vmax=1,  # 색상 범위 고정
    square=True
)
plt.title('변수 간 상관관계 히트맵')
plt.tight_layout()
plt.show()
```

히트맵 읽는 법




빨강 (양의 상관)

두 변수가 함께 증가



파랑 (음의 상관)

한 변수 증가 → 다른 변수 감소



흰색 (≈ 0)

거의 관련 없음



대각선 = 1.0

자기 자신과의 상관 → 항상 1

💡 주의사항

- 상관관계 $\neq$ 인과관계
- 선형 관계만 측정 (비선형 패턴은 놓칠 수 있음)

다변량 분석 ② — pairplot & hue 활용

PART 3

pairplot — 변수 쌍 한번에

```
# 기본
sns.pairplot(
    df[['수학점수', '영어점수', '과학점수']]
)

# 그룹별 구분 (hue)
sns.pairplot(
    df,
    vars=['수학점수', '영어점수', '과학점수'],
    hue='성별',
    diag_kind='kde',
    plot_kws={'alpha': 0.5}
)
plt.show()
```

hue 로 그룹 구분

```
# scatterplot + hue
sns.scatterplot(
    data=df,
    x='수학점수', y='영어점수',
    hue='성별',
    alpha=0.6
)

# boxplot + hue
sns.boxplot(
    data=df,
    x='지역', y='수학점수',
    hue='성별'
)
```

대각선 (diag_kind)

단변량 분포 (hist/kde)

비대각선 (plot_kws)

변수 쌍 산점도

hue=(범주형 변수)

그룹별 색상 구분

⚠ 변수가 많을수록 느려집니다 — 10개 이상이면 핵심 변수만 선택하세요

EDA 체크리스트 — 분석 전 꼭 거치세요

기본 확인

- ☒ shape, dtypes, isnull().sum()
- ☒ duplicated() 중복 제거
- ☒ describe() 기술통계 파악

이변량

- ☒ 수치×수치: corr + scatter
- ☒ 범주×수치: groupby + boxplot
- ☒ 범주×범주: crosstab + heatmap

단변량

- ☒ 수치형: histplot + boxplot
- ☒ 범주형: value_counts()
- ☒ 왜도 확인 → 변환 필요 여부

다변량

- ☒ 상관행렬 히트맵
- ☒ pairplot (핵심 변수)
- ☒ hue로 그룹 비교

인사이트 도출 — "왜?"를 계속 질문하세요

🔍 EDA 스토리 예시 — 학생 성적 데이터



발견

수학 점수 boxplot에서 낮은 이상치 발견 (22점)



질문

"특정 그룹에서 집중되나?" → 성별로 groupby



발견

남학생 수학 +8점 · 여학생 영어 +5점 차이 발견



질문

"학원 수강 여부와 관련?" → crosstab 확인



가설

"학원 미수강 남학생에서 수학 낮은 점수 집중"
→ 다음 단계: 통계 검정 또는 머신러닝으로 확인

오늘 배운 핵심 코드 한눈에

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

df = pd.read_csv('student_score.csv', encoding='utf-8-sig')

# — 단변량 —————
df.describe() # 기술통계
df['성별'].value_counts(normalize=True) # 범주형 비율
sns.histplot(df['수학점수'], kde=True) # 분포 곡선
sns.boxplot(data=df, y='수학점수') # 이상치 확인

# — 이변량 —————
df[['수학점수', '영어점수', '과학점수']].corr() # 상관계수
sns.scatterplot(data=df, x='수학점수', y='영어점수')
df.groupby('성별')['수학점수'].mean() # 그룹 평균
pd.crosstab(df['성별'], df['학원수강']) # 교차표

# — 다변량 —————
corr = df.select_dtypes('number').corr()
sns.heatmap(corr, annot=True, fmt='.2f', cmap='coolwarm')
sns.pairplot(df, hue='성별',
             vars=['수학점수', '영어점수', '과학점수'])
```


오늘의 핵심 정리

📊 단변량 — describe · value_counts · histplot · boxplot 으로 각 변수 파악

👁 이변량 — corr · scatter · groupby · crosstab 으로 두 변수 관계 탐색

🗺 다변량 — 상관행렬 히트맵 + pairplot 으로 전체 구조 조망

💡 EDA의 본질 — "왜?" 를 반복하며 가설을 좁히는 탐색 과정

📅 다음 시간 — 7강

머신러닝 입문 : 선형 회귀 & 분류

scikit-learn · train_test_split · 모델 평가 · 예측

수고하셨습니다! 질문이 있으시면 손을 들어주세요 🙋