

데이터 분석 6강

탐색적 데이터 분석

EDA (Exploratory Data Analysis)

데이터와 친해지는 시간 — 분석 전 반드시 거쳐야 할 탐색 과정

 단변량

 이변량

 다변량

Python 데이터 분석 실무 과정

EDA란? — 왜 해야 할까요

EDA (Exploratory Data Analysis)

본격 분석 전, 데이터의 구조·분포·관계를 눈으로 직접 확인하는 탐색 과정

진찰 없이 처방?

의사가 환자를 보지도 않고 처방전을 쓰면 위험합니다.
EDA 없이 분석하면 같은 실수를 합니다.

지도 없이 여행?

낯선 도시에서 지도 없이 목적지를 찾아가기는 어렵죠.
EDA는 데이터의 지도를 그리는 과정입니다.

EDA의 역할

데이터에 어떤 변수가 있는지
이상한 값은 없는지
변수끼리 어떤 관계인지 파악합니다.

EDA를 하면 알 수 있는 것들

- ✓ 데이터 크기·구조 파악 (몇 행? 몇 열? 자료형은?)
- ✓ 결측치·이상치 위치 발견 → 전처리 방향 결정
- ✓ 변수 간 숨겨진 패턴과 관계 탐색
- ✓ 분석 가설 수립 → 다음 단계(모델링) 방향 설정

EDA 분석 흐름 & 오늘의 데이터

1

데이터
로드·확인

shape / dtypes
isnull / head

2

단변량
분석

변수 하나씩
분포·특성

3

이변량
분석

두 변수
관계 탐색

4

다변량
분석

전체 구조
한눈에 조망

5

인사이트
도출

"왜?" 질문
가설 수립

📁 student_score.csv — 300명 · 8열

변수명	설명	유형
수학점수	0~100점	수치형
영어점수	0~100점	수치형
과학점수	0~100점	수치형
성별	M / F	범주형
나이	15~19세	수치형
지역	서울/경기/인천...	범주형
학원수강	예 / 아니오	범주형

💡 수치형·범주형 모두 포함 → 모든 이변량 조합 실습 가능

📖 오늘 배울 분석 도구

PART 1 단변량

describe() · value_counts() · histplot · boxplot

PART 2 이변량

scatter · corr() · groupby · crosstab

PART 3 다변량

상관행렬 히트맵 · pairplot · hue

💡 수치형 3개 + 범주형 5개 — EDA 전 유형 실습 가능



PART 1

단변량 분석 (Univariate Analysis)

🕒 약 15분

변수 하나씩 살펴보기 — 분포·특성·이상치

"이 변수는 어떻게 생겼나?" 를 묻는 단계

단변량 분석 ① — 기술통계로 변수 파악하기

PART 1

📋 데이터를 처음 받으면 — 기본 4가지 확인

```
df.shape
```

행 수 × 열 수 — 데이터 규모 파악

→ (300, 8) → 300명, 8개 항목

```
df.dtypes
```

각 열의 자료형 — 분석 방법이 달라짐

→ 수치형 vs 범주형 구분 필수

```
df.isnull().sum()
```

열별 결측치 개수 — 전처리 방향 결정

→ 0이면 완벽, 숫자가 있으면 5강 처리 필요

```
df.head(5)
```

처음 5행 미리보기 — 실제 데이터 눈으로 확인

→ 값 형식·오타·이상한 패턴 발견 가능

📊 describe() — 기술통계 한눈에

• `mean ≈ median (50%)` → 대칭 분포 → 정규분포에 가까움

• `mean >> median`

→ 오른쪽 꼬리 → 이상치 가능성

• `std(표준편차) 크다` → 값이 넓게 퍼져 있음 → 분포 확인 필요

• `min / max`


→ 극단값 존재 여부 → 이상치 1차 점검

단변량 분석 ② — 분포를 그림으로 보기

PART 1


히스토그램 (histplot) — 분포 모양 확인

- ▶ 봉우리 위치 데이터가 가장 많이 모인 값
- ▶ 좌우 대칭 종 모양이면 정규분포에 가까움
- ▶ 오른쪽 꼬리 이상치가 있다는 신호
- ▶ KDE 곡선 분포를 부드럽게 추정한 선



종 모양 분포 예시

박스플롯 (boxplot) — 이상치·퍼짐 확인



☆ 두 그래프를 함께 쓰는 이유

히스토그램 → 전체 분포의 모양을 파악
박스플롯 → 이상치의 위치를 정확히 확인
두 그래프를 나란히 보면 분포 파악이 훨씬 빠릅니다



PART 2

이변량 분석 (Bivariate Analysis)

🕒 약 20분

두 변수의 관계 탐색 — 3가지 조합

수치형 × 수치형

산점도 · 상관계수

범주형 × 수치형

groupby · boxplot

범주형 × 범주형

교차표 · 히트맵

이변량 분석 ① — 수치형 × 수치형

PART 2


① 산점도 — 두 수치 변수의 관계를 점으로



참고 코드

```
sns.scatterplot(data=df, x='수학점수', y='영어점수')  
df[['수학점수', '영어점수', '과학점수']].corr()
```

② 상관계수 — 관계의 강도를 숫자로



$|r| \geq 0.7$

강한 상관

0.4 ~ 0.7

보통 상관

0.2 ~ 0.4

약한 상관

< 0.2

거의 무관

⚠ 꼭 기억하세요


- 상관관계 ≠ 인과관계 (함께 변한다 ≠ 원인이다)
- 선형 관계만 측정 (곡선 관계는 포착 못 함)
- 이상치 하나가 상관계수를 크게 바꿀 수 있음

이변량 분석 ② — 범주형 × 수치형

PART 2

"성별에 따라 수학 점수가 다를까?" — 그룹을 나눠서 비교합니다

① groupby — 그룹별 통계



예시 결과: 성별 수학 평균 영어 평균 과학 평균

M	72.1	68.4
F	69.7	73.8

참고 코드

```
df.groupby('성별')['수학점수'].agg(['mean', 'median', 'std'])
```

② 그래프로 비교하기 — 어떤 그래프를 쓸까?



boxplot

→ 분포 전체를 보고 싶을 때
중앙값·IQR·이상치까지 한번에



barplot

→ 그룹 평균만 비교할 때
평균과 오차막대로 간결하게



violinplot

→ 분포 형태까지 자세히 볼 때
boxplot + 분포 형태 결합

참고 코드

```
df.groupby('성별')[['수학점수', '영어점수']].mean()  
sns.boxplot(data=df, x='성별', y='수학점수')
```

이변량 분석 ③ — 범주형 × 범주형

PART 2

"성별에 따라 학원 수강 비율이 다를까?" — 빈도표로 교차 확인

① 교차표 (crosstab) — 두 범주형 변수의 빈도

	학원 아니오	학원 예
여학생 (F)	72명	86명
남학생 (M)	88명	54명

② 비율로 바꾸기 — normalize 옵션


`normalize=False`
기본값 — 빈도 수로 표시 → 72, 86, 88, 54

`normalize='index'`
행(그룹) 기준 비율 → F: 아니오 45% / 예 55%

`normalize='all'`
전체 기준 비율 → 전체 300명 중 몇 %

```
pd.crosstab(df['성별'], df['학원수강'], normalize='index')
```

③ 히트맵 — 교차표를 색으로 시각화



색이 진할수록 빈도 높음

💡 이 교차표에서 읽을 수 있는 것

- 여학생(F)은 학원 수강 비율이 더 높음 (54% vs 38%)
- 남학생(M)은 학원 미수강 비율이 높음
- 분포가 다르다 → 성별과 학원수강이 관련될 가능성 있음



PART 3

다변량 분석 (Multivariate Analysis)

🕒 약 15분


여러 변수를 한 번에 — 전체 구조 조망

"숲을 보는" 단계 — 개별 나무(변수)에서 눈을 들어 전체 지도를 그립니다

다변량 분석 ① — 상관행렬 히트맵

PART 3

모든 수치형 변수 쌍의 상관계수를 색상으로 "전체를 한눈에"



색상 범례

- 강한 양의 상관
- 보통 양의 상관
- 약한 상관
- 자기 자신 (=1)

히트맵 읽는 법

- 진한 파랑 → 강한 양의 상관**
두 변수가 함께 증가하는 관계
영어·과학 (0.72) → 같이 잘하는 경향
- 연한 색 → 약한 상관**
두 변수 사이에 뚜렷한 선형 관계 없음
나이와 각 점수 (0.05~0.12)
- 대각선 = 1.0**
자기 자신과의 상관 → 항상 1
이 칸은 무시하세요
- 빨간 계열 → 음의 상관**
coolwarm 팔레트에서 빨강 쪽으로 갈수록
한 변수 증가시 다른 변수 감소

💡 상관관계 ≠ 인과관계 · 선형 관계만 측정 · 이상치에 민감

다변량 분석 ② — pairplot & hue

PART 3

pairplot — 변수 쌍 전체를 격자로 한번에 시각화



대각선

각 변수의 분포
(histogram 또는 kde 곡선)

비대각선

두 변수의 산점도
위아래 대칭으로 같은 정보

hue 추가

hue='성별' → 점 색을
그룹으로 구분
패턴 차이를 한눈에 비교 가능

☆ hue가 강력한 이유

단순 산점도에서는 보이지 않던 그룹 간 차이가
hue를 추가하면 바로 드러납니다.
예시: 수학·영어 산점도에서 남·여 점 분포가 다르게 모이는 패턴 발견

⚠ 변수가 많을수록 느려집니다 — 10개 이상이면 핵심 변수만 선택하세요

```
sns.pairplot(df, vars=['수학점수', '영어점수', '과학점수'], hue='성별')
```

실습 ① — 단변량 분석 직접 해보기

실습

🕒 5분 | student_score.csv 단변량 분석 미션

01 df.describe() → 평균·표준편차·최솟값·최댓값 확인

02 sns.histplot(수학점수) → 분포 모양 (좌우 대칭?)

03 sns.boxplot(수학점수) → 이상치가 있나?

04 df["성별"].value_counts() → 남·여 비율은?

💡 힌트 → describe | histplot | boxplot | value_counts

```
# 빈칸을 채워 코드를 완성하세요

import pandas as pd
import seaborn as sns

df = pd.read_csv("student_score.csv")

# 1. 기술통계
df.__( )

# 2. 분포 시각화
sns.__(df, x='__')

# 3. 이상치 확인
sns.__(df, y='__')

# 4. 범주형 빈도
df['성별'].__( )
```

실습 ② — 이변량 분석 직접 해보기

실습

🕒 5분 | 두 변수의 관계 탐색 미션

01 scatterplot(수학점수, 영어점수) → 양의 상관관계?

02 df.corr() → 가장 강한 상관관계는 어떤 두 변수?

03 groupby(성별)[수학점수].mean() → 남·여 평균 차이는?

04 교차표: pd.crosstab(성별, 합격여부) → 합격률 비교

💡 힌트 → scatterplot | corr | groupby | mean | crosstab

```
# 빈칸을 채워 코드를 완성하세요

# 1. 수치×수치 산점도
sns.__(df,
        x='수학점수', y='__')

# 2. 상관관계수 행렬
df.__(numeric_only=True)

# 3. 범주×수치 평균 비교
df.__( '성별' ) [ '수학점수' ].__( )

# 4. 범주×범주 교차표
pd.__(df[ '성별' ],
      df[ '합격여부' ],
      normalize='index')
```

실습 ③ — 다변량 분석 직접 해보기

실습

🕒 5분 | 전체 변수 구조 파악 미션

01 상관행렬 히트맵 그리기 → 색이 진한 칸은 어디?

02 pairplot 그리기 → 수학.영어.과학 변수 3개

03 hue='성별' 추가 → 남녀 점이 다르게 분포하나?

04 발견한 인사이트를 한 문장으로 정리해보세요

💡 힌트 → corr | heatmap | pairplot | 성별

```
# 빈칸을 채워 코드를 완성하세요

# 1. 상관행렬 히트맵
corr = df.__(numeric_only=True)
sns.__(corr,
        annot=True,
        cmap='coolwarm')

# 2. pairplot
sns.__(df,
        vars=['수학점수',
              '영어점수', '과학점수'],
        hue='__')

# 3. 인사이트 메모
# → _____
```

EDA 체크리스트 — 순서대로 거치세요

기본 확인

- ☒ shape · dtypes 로 규모와 자료형 파악
- ☒ isnull().sum() 결측치 확인 → 5강 처리
- ☒ duplicated() 중복 행 제거
- ☒ describe() 기술통계 훑기

이변량 분석

- ☒ 수치×수치: corr() + scatterplot
- ☒ 범주×수치: groupby + boxplot
- ☒ 범주×범주: crosstab + heatmap
- ☒ 차이·관계 발견 → 가설 메모

단변량 분석

- ☒ 수치형: histplot 분포 확인
- ☒ 수치형: boxplot 이상치 탐지
- ☒ 범주형: value_counts() 빈도·비율
- ☒ 분포 형태 → 왜도 크면 변환 검토

다변량 분석

- ☒ 상관행렬 히트맵 — 전체 조망
- ☒ pairplot — 변수 쌍 시각화
- ☒ hue 추가 → 그룹 패턴 비교
- ☒ 핵심 인사이트 정리

인사이트 도출 — EDA는 "왜?"를 반복하는 과정

🔍 EDA 인사이트 도출 예시 — student_score.csv

👁
발견

수학 점수 boxplot에서 22점짜리 낮은 이상치 발견

단변량 분석에서 포착

❓
질문

"이 낮은 점수가 특정 그룹에 집중되나?" → 성별로 groupby

이변량 분석으로 이동

👁
발견

남학생 수학 +8점 차이, 여학생 영어 +5점 차이 발견

그룹 간 차이 확인

❓
질문

"학원 수강 여부가 영향?" → crosstab으로 확인

범주형 교차 분석

💡
가설

"학원 미수강 남학생에서 수학 낮은 점수 집중" → 통계 검정으로 확인 필요

다음 단계: 통계·머신러닝

오늘 배운 핵심 — 개념 정리

PART1 단변량

▶ `describe()` → 평균·표준편차·사분위수로 변수 수치 파악

▶ `value_counts()` → 범주형 변수 빈도와 비율 확인

▶ `histplot` → 분포 모양 (대칭? 꼬리?) 시각화

▶ `boxplot` → 중앙값·IQR·이상치 위치 확인

PART2 이변량

▶ 수치×수치: 산점도 + 상관계수 (-1 ~ +1)

▶ 범주×수치: `groupby` 통계 + `boxplot` 분포 비교

▶ 범주×범주: `crosstab` 빈도표 + 히트맵 시각화

▶ 상관관계 ≠ 인과관계 — 항상 주의

PART3 다변량

▶ 상관행렬 히트맵 → 모든 변수 쌍 색상으로 조망

▶ `pairplot` → 격자 형태로 분포 + 산점도 한번에

▶ `hue` 추가 → 그룹 간 패턴 차이 시각화

▶ 변수 많으면 핵심 변수만 선택하여 사용

💡 EDA의 핵심 = 그래프를 보며 "왜?"를 반복하고, 가설을 좁혀가는 과정

오늘의 핵심 정리

 단변량 — 변수 하나씩, describe · histplot · boxplot 으로 분포와 특성 파악

 이변량 — 두 변수 관계, 수치×수치·범주×수치·범주×범주 조합별 탐색

 다변량 — 상관행렬 히트맵 + pairplot 으로 전체 구조를 한눈에 조망

 EDA의 본질 — "왜?" 를 반복하며 데이터에서 인사이트를 끌어내는 탐색 과정

다음 시간 — 6강 실습

오늘 배운 EDA를 직접 코드로 실습합니다

student_score.csv로 단변량 → 이변량 → 다변량 전 과정을 혼자 완성해보세요

실습 전 준비: student_score.csv를 Colab에 업로드해주세요

수고하셨습니다! 질문이 있으시면 손을 들어주세요 