


PYTHON을 이용한 데이터 분석 · 9강

회귀란?

선형회귀의 원리

이론편 — 회귀의 개념부터 최소제곱법·경사하강법까지



오늘의 학습 목표



회귀(Regression)의 개념 이해

회귀가 무엇을 예측하는 문제인지, 분류와 어떻게 다른지 설명할 수 있다.



선형회귀 모델의 구조 파악

$\hat{y} = wx + b$ 에서 가중치 w 와 절편 b 가 갖는 의미를 이해한다.



파라미터를 찾는 원리 이해

잔차 → 비용함수(MSE) → 최소제곱법·경사하강법으로 이어지는 흐름을 이해한다.



회귀 모델 평가지표 해석

MSE · RMSE · MAE · R^2 의 의미와 차이를 구분한다.

회귀(Regression)란 무엇인가?

정의 입력 변수 X 와 연속적인 숫자값 y 사이의 관계를 함수 형태로 모델링하여, 새로운 입력에 대한 값을 예측하는 **지도학습** 방법

용어의 유래

19세기 프랜시스 골턴(F. Galton)이 부모와 자녀의 키를 연구하며 발견한 "평균으로의 회귀(regression to the mean)" 현상에서 유래

예시 공부 시간 → 시험 점수 · 집 면적 → 집값 · 기온 → 아이스크림 판매량

입력 X (특성: 면적, 시간 ...)



회귀 모델 $f(X)$



예측값 $\hat{y}$ (연속값: 83.5점)

회귀 vs 분류 — 무엇이 다른가?

회귀 (Regression)

예측 대상 연속적인 숫자 (실수)

대답하는 질문 “얼마나?” — How much?

출력 예시 83.5점, 3억 2천만 원, 24.1°C

대표 예 집값 예측 · 수요 예측 · 주가 예측

분류 (Classification)

예측 대상 정해진 범주 (카테고리)

대답하는 질문 “어느 쪽?” — Which one?

출력 예시 합격/불합격, 스팸/정상, 품종 A·B·C

대표 예 스팸 필터 · 질병 진단 · 이미지 분류

공통점 둘 다 정답(레이블)이 있는 데이터로 배우는 지도학습(Supervised Learning)입니다.

선형회귀 모델 — 직선으로 관계를 표현한다

$$\hat{y} = wx + b$$

예측값 = 가중치 × 입력 + 절편

$\hat{y}$ (예측값)

모델이 출력하는 값.
실제 정답 y 와 구분하기 위해 $\hat{y}$ (y-hat)
으로 표기

w (가중치·기울기)


x 가 1 증가할 때 $\hat{y}$ 가 얼마나 변하는지
·
입력의 영향력을 나타냄

b (절편·편향)

$x = 0$ 일 때의 예측값.
직선의 상하 위치를 결정

다중 선형회귀 특성이 여러 개면 $\hat{y} = w_1x_1 + w_2x_2 + \dots + w_nx_n + b$ 로 확장됩니다. **학습의 목표 = 데이터에 가장 잘 맞는 w 와 b 를 찾는 것!**

어떤 직선이 '좋은' 직선인가? — 잔차



잔차 (Residual)

실제값과 예측값의 차이

$$e = y - \hat{y} \text{ (실제값 - 예측값)}$$

좋은 직선 = 잔차가 전체적으로 작은 직선

모든 점을 지날 수는 없으므로, 전체 오차를 최소화하는 직선을 찾습니다.

잠깐! 잔차를 그냥 더하면 +와 -가 상쇄되어 0에 가까워집니다. 그래서 **제곱해서 더합니다**
→ 다음 슬라이드

비용함수 — 평균제곱오차 (MSE)

$$\text{MSE}(\mathbf{w}, \mathbf{b}) = 1/n \cdot \sum (y_i - \hat{y}_i)^2$$

모든 데이터의 (실제값 - 예측값)² 을 평균낸 값 — “직선이 데이터에서 얼마나 벗어났는가”의 점수

제공하는 이유 ①

부호(+/-)가 사라져 오차가 상쇄되지 않음

제공하는 이유 ②

큰 오차일수록 훨씬 큰 벌점 → 큰 실수에 민감

수학적 이점

매끄러운 함수라 미분 가능 → 최적화가 쉬움

핵심 학습이란 결국 **MSE**를 가장 작게 만드는 **w**와 **b**를 찾는 최적화 문제입니다. 그 방법이 바로 최소제곱법과 경사하강법입니다.

METHOD 1

최소제곱법 (Ordinary Least Squares)

아이디어 MSE는 w, b 에 대한 아래로 볼록한(convex) 함수 → 미분해서 0이 되는 지점이 곧 최솟값. 이를 풀면 정답이 공식으로 바로 나옵니다 (해석적 해).

$$w = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

$$b = \bar{y} - w \cdot \bar{x}$$

$\bar{x}, \bar{y}$ 는 각각 x 와 y 의 평균



한 번의 계산으로 끝

반복 없이 공식 대입만으로 정확한 최적해



직관적 해석

$w = \text{공분산}(x, y) \div \text{분산}(x)$ 구조



sklearn의 기본 원리

LinearRegression이 이 방식으로 해를 구함

한계 특성이 매우 많거나 데이터가 거대하면 계산 비용이 커짐 → 이때 등장하는 것이 경사하강법입니다.

METHOD 2

경사하강법 (Gradient Descent)

아이디어 — 안개 낀 산에서 내려가기


현재 위치에서 비용함수의 기울기(경사)를 계산하고, 비용이 낮아지는 방향으로 w 와 b 를 조금씩 반복해서 이동합니다.

$$w \leftarrow w - \alpha \cdot \partial \text{MSE} / \partial w$$

α (학습률, learning rate)

한 걸음의 크기. 너무 크면 → 발산(최솟값을 지나침) / 너무 작으면 → 학습이 매우 느림

왜 배우나? 대용량·고차원 데이터, 그리고 딥러닝까지 — 거의 모든 머신러닝 학습의 공통 엔진입니다.



기울기를 따라 한 걸음씩 바닥(최솟값)으로

회귀 모델은 어떻게 평가하는가?

MSE

$$1/n \sum (y - \hat{y})^2$$

평균제곱오차. 학습(최적화)의 기준. 제곱 때문에 단위가 원래 값과 달라 직관적 해석은 어려움.

RMSE

$$\sqrt{\text{MSE}}$$

MSE에 루트를 씌워 원래 데이터와 같은 단위로 복원. "평균적으로 약 3.2점 정도 틀린다"처럼 해석 가능.

MAE

$$1/n \sum |y - \hat{y}|$$

평균절대오차. 오차의 절댓값 평균. 제곱하지 않으므로 이상치(outlier)의 영향에 덜 민감.

R² (결정계수)

$$1 - \text{SSE}/\text{SST}$$

모델이 데이터의 변동을 얼마나 설명하는가. 1에 가까울수록 좋고, 0이면 평균으로 찍는 수준. 단위가 없어 모델 간 비교에 유용.

선형회귀의 가정과 주의점



선형성 (Linearity)

x와 y의 관계가 대체로 직선 형태여야 함. 곡선 관계라면 변환(로그 등)이나 다항회귀를 고려.



오차의 독립성 · 등분산성

잔차가 특정 패턴 없이 고르게 퍼져 있어야 함. 잔차 그래프(residual plot)로 확인.



이상치(Outlier)에 민감

오차를 제곱하므로 극단값 하나가 직선을 크게 왜곡할 수 있음 → 학습 전 이상치 탐지 필수.



상관관계 ≠ 인과관계

회귀 계수가 크다고 해서 x가 y의 원인이라는 뜻은 아님. 해석에 항상 주의.

파이썬에서는 어떻게 할까? — 다음 강의 예고

```
from sklearn.linear_model import LinearRegression

model = LinearRegression()
model.fit(X, y)          # 학습: 최적의 w, b 탐색

print(model.coef_)       # w (가중치)
print(model.intercept_)  # b (절편)

y_pred = model.predict(X_new) # 새 데이터 예측
```

`fit()`

오늘 배운 최소제곱법으로 w, b 를 계산하는 단계

`coef_ / intercept_`

학습된 기울기 w 와 절편 b — 오늘의 수식 그대로!

`predict()`

$\hat{y} = wx + b$ 에 새 x 를 대입해 예측값 계산

이 외에도 `numpy.polyfit()`, `scipy.stats.linregress()`로도 선형회귀를 수행할 수 있습니다. 다음 강의에서 실제 데이터로 직접 구현해 봅니다!

SUMMARY

오늘의 핵심 정리

- ✓ 회귀 연속적인 숫자를 예측하는 지도학습 — “얼마나?”에 답한다 (분류는 “어느 쪽?”)
- ✓ 선형회귀 모델 $\hat{y} = wx + b$. 학습이란 데이터에 가장 잘 맞는 w 와 b 를 찾는 것
- ✓ 비용함수 MSE 잔차를 제공해 평균낸 값 — 이 값을 최소화하는 것이 학습의 목표
- ✓ 두 가지 해법 최소제곱법(공식으로 한 번에) vs 경사하강법(기울기를 따라 반복적으로)
- ✓ 평가지표 RMSE·MAE는 “평균 몇 점 틀리나”, R^2 는 “변동을 얼마나 설명하나”

NEXT 10강 — 파이썬으로 선형회귀 구현하기 (scikit-learn 실습)