


PYTHON을 이용한 데이터 분석 · 10강

분류란?

결정트리의 원리

이론편 — 스무고개에서 지니 불순도까지



오늘의 학습 목표



분류(Classification)의 개념 이해

분류가 무엇을 예측하는 문제인지, 회귀와 어떻게 다른지 설명할 수 있다.



결정트리의 구조 파악

루트 노드 · 내부 노드 · 리프 노드로 이루어진 '질문의 나무'를 읽을 수 있다.



분할 기준의 원리 이해

불순도(지니) → 정보 이득으로 이어지는 '좋은 질문 고르기'의 원리를 이해한다.



분류 모델 평가지표 해석

정확도의 함정과 혼동행렬, 정밀도·재현율의 의미를 구분한다.

분류(Classification)란 무엇인가?

정의 입력 변수 X 를 보고 정해진 범주(클래스) 중 하나를 고르는 **지도학습** 방법. "어느 쪽?"이라는 질문에 답한다.

9강 복습 — 회귀와의 차이

회귀는 연속적인 숫자(83.5점)를, 분류는 범주(합격/불합격)를 내놓습니다. 출력의 형태가 문제의 종류를 결정합니다.

예시 스팸/정상 메일 · 질병 양성/음성 · 고객 이탈 여부 · 붓꽃 품종 구분

입력 X (기온, 시간대 ...)



분류 모델 $f(X)$



아이스 ☐

핫 ☕

정해진 보기 중 하나를 선택!

분류 문제의 두 가지 형태

이진 분류 (Binary)

보기의 수 딱 2개

예시 스팸/정상 · 양성/음성 · 이탈/유지

오늘의 예제 아이스 vs 핫

특징 분류의 기본형 — 평가지표도 여기서 출발

다중 클래스 (Multi-class)

보기의 수 3개 이상

예시 붓꽃 3품종 · 손글씨 숫자 0~9


원리 이진 분류의 자연스러운 확장

특징 결정트리는 다중 클래스를 그대로 처리 가능

주의 별점 1~5 예측처럼 문제 정의에 따라 회귀로도, 다중 분류로도 풀 수 있는 경우가 있습니다 (9강 미니 퀴즈 ③).

결정트리 — 스무고개로 답을 찾는 모델

결정트리는 예/아니오 질문을 반복하며 데이터를 나누는 모델입니다. 스무고개와 완전히 같은 구조!



루트 노드

맨 위의 첫 질문. 가장 중요한 질문이 온다

내부 노드

중간의 질문들. 가지(branch)로 갈라짐

리프 노드

더 이상 질문이 없는 끝. 예측(정답)이 담김

예측 방법 새 손님이 오면 루트부터 질문을 따라 내려가 도착한 리프의 답을 출력. 25°C 오후 손님 → 왼쪽 → 아이스!

KEY QUESTION


어떤 질문이 '좋은' 질문인가? — 순도

9강에서 '좋은 직선'의 기준이 필요했듯, 오늘은 '좋은 질문'의 기준이 필요합니다. 답: **나눈 뒤 그룹이 순수해지는 질문!**

좋은 질문: 기온 $\geq 23^{\circ}\text{C}$?



예 → 아이스 9 : 핫 1




아니오 → 아이스 1 : 핫 9

나쁜 질문: 단골 손님인가?



예 → 아이스 5 : 핫 5



아니오 → 아이스 5 : 핫 5

→ 양쪽 모두 한쪽으로 쏠림 = 순수(pure)에 가까움. 답이 거의 정해진다!

→ 나뉘어도 여전히 반반 = 불순(impure). 질문한 보람이 없다.

핵심 '쏠린 정도'를 숫자로 잴 수 있다면, 컴퓨터가 스스로 좋은 질문을 고를 수 있습니다. 그 숫자가 바로 **불순도(Impurity)** → 다음 슬라이드

불순도를 재는 자 — 지니 불순도 (Gini)

$$\text{Gini} = 1 - \sum p_k^2 \quad (p_k = \text{클래스 } k \text{의 비율})$$

“아무 데이터나 하나 뽑아 비율대로 찍었을 때 틀릴 확률” — 0이면 완벽히 순수, 클수록 뒤섞임

완전히 순수

아이스 10 : 핫 0

$$1 - (1.0^2 + 0^2) = 0$$

약간 섞임

아이스 8 : 핫 2

$$1 - (0.8^2 + 0.2^2) = 0.32$$

최악 (반반)


아이스 5 : 핫 5

$$1 - (0.5^2 + 0.5^2) = 0.5$$

이진 분류에서 지니는 0 (순수) ~ 0.5 (반반) 사이. 참고: 엔트로피라는 다른 자도 있으며 결과는 대체로 비슷 — sklearn 기본값은 지니입니다.

질문 고르기 — 불순도가 가장 많이 줄어드는 쪽

정보 이득 = 부모의 불순도 - 자식들의 불순도(가중평균) → 이득이 가장 큰 질문을 선택!



이득 = $0.50 - (11/20 \times 0.30 + 9/20 \times 0.20) = 0.50 - 0.25 = 0.25$ → 모든 후보 질문 중 이득 최대를 선택

트리 학습 = 이 과정을 나뉜 그룹마다 반복(재귀). 리프가 충분히 순수해지면 멈춘다.

트리를 끝까지 키우면 안 되는 이유 — 과적합


멈추지 않으면? 리프가 전부 순수해질 때까지 나누면 훈련 데이터를 통째로 암기한 트리가 됩니다. 훈련 정확도 100%, 새 데이터에서는 엉망 — 이것이 **과적합(Overfitting)** 입니다.

적당한 트리 (깊이 2~4)



규칙이 단순해 새 데이터에도 일
반화. 사람이 읽고 설명할 수 있음

너무 깊은 트리



예외 하나하나까지 암기. '25.3°C
화요일 단골은 핫' 같은 규칙 —
우연을 법칙으로 착각.

처방 성장을 미리 제한: 최대 깊이(max_depth) · 리프 최소 샘플 수(min_samples_leaf) 지정, 또는 다 키운 뒤 가지치기(pruning)

분류 모델은 어떻게 평가하는가?

정확도의 함정 암 환자가 1%인 데이터에서 무조건 '정상'이라 답해도 정확도 99%! 그래서 **혼동행렬**로 쪼개 봅니다.

혼동행렬 (Confusion Matrix)

실제 ↓ / 예측 →

양성 예측

음성 예측

실제 양성

TP (참 양성)

FN (거짓 음성)

실제 음성

FP (거짓 양성)

TN (참 음성)

정확도 (Accuracy)

$$(TP+TN) / \text{전체}$$

전체 중 맞힌 비율

정밀도 (Precision)

$$TP / (TP+FP)$$

'양성'이라 한 것 중 진짜 비율 — 스팸함의 억울한 정상 메일 줄이기

재현율 (Recall)

$$TP / (TP+FN)$$

실제 양성 중 잡아낸 비율 — 암 환자를 놓치지 않기

핵심 정밀도와 재현율은 시소 관계. 무엇이 더 치명적인 실수인지(FP vs FN)에 따라 중시할 지표가 달라집니다.

결정트리의 장점과 한계



장점 ① 해석이 쉽다

왜 그렇게 예측했는지 규칙(질문 경로)을 사람이 그대로 읽을 수 있음 — 화이트박스 모델



장점 ② 전처리가 적다

특성의 스케일 조정(표준화)이 필요 없고, 숫자·범주형 특성을 모두 다룸



한계 ① 과적합되기 쉽다

깊이 제한 없이 키우면 훈련 데이터를 암기 → max_depth 등으로 반드시 제어



한계 ② 불안정하다

데이터가 조금만 바뀌어도 트리 모양이 크게 변함 → 여러 트리의 투표(랜덤 포레스트)로 보완

파이썬에서는 어떻게 할까? — 다음 강의 예고

```
from sklearn.tree import DecisionTreeClassifier
from sklearn.tree import plot_tree

model = DecisionTreeClassifier(
    max_depth=3)          # 과적합 방지!
model.fit(X, y)           # 학습: 질문 고르기

pred = model.predict(X_new) # 분류 예측
plot_tree(model)          # 트리를 그림으로!
```

`fit( )`

오늘 배운 정보 이득 계산으로 질문을 고르는 단계

`max_depth=3`

슬라이드 9의 과적합 처방 — 트리 깊이 제한

`plot_tree( )`

학습된 스무고개를 그림으로 확인 — 해석 가능성!

9강과 코드 구조가 똑같죠? `fit` / `predict` 라는 `sklearn`의 통일된 문법 덕분입니다. 회귀든 분류든 배우는 방식은 하나 — 다음 강의에서 붓꽃(`iris`) 데이터로 직접 실습합니다!

SUMMARY

오늘의 핵심 정리

- ✓ **분류** 정해진 범주 중 하나를 고르는 지도학습 — “어느 쪽?”에 답한다 (회귀는 “얼마나?”)
- ✓ **결정트리** 예/아니오 질문을 반복하는 스무고개 — 루트·내부·리프 노드로 구성
- ✓ **지니 불순도** 그룹이 뒤섞인 정도(0~0.5). 낮을수록 순수 — 분류판 ‘성적표’
- ✓ **정보 이득** 불순도를 가장 많이 줄이는 질문을 고르고, 그룹마다 재귀 반복 = 학습
- ✓ **과적합과 평가** 깊이 제한으로 암기 방지 · 정확도의 함정은 혼동행렬(정밀도·재현율)로 해결

NEXT 10강 실습 — 붓꽃(iris) 데이터로 결정트리 분류기 만들기 (scikit-learn)