

PYTHON을 이용한 데이터 분석 · 10강 실습

파이썬으로 결정트리 분류 구현하기

```
model.fit(X, y)
accuracy = 0.87
Gini = 0.30
```

실습편 (2시간) — 음료 선택 예측 모델을 직접 만들고 성능을 평가해 보자

2시간의 여정을 한눈에

Part 0	환경 설정 (10분)	필요한 라이브러리 import, 데이터 로드
Part 1	데이터 탐색 (15분)	df.head() / 분포 시각화 / 클래스 비율
Part 2	손으로 하는 결정트리 (25분)	단계별로 나누기 · 지니 계산 · 트리 그리기
Part 3	sklearn으로 자동 학습 (20분)	DecisionTreeClassifier · fit · predict
Part 4	성능 평가 (30분)	혼동행렬 · 정확도/정밀도/재현율 계산
Part 5	깊이 실험 (20분)	max_depth 조정으로 과적합 이해 · 최적값 찾기

환경 설정 체크리스트

1

Import 확인

`numpy / pandas / sklearn.tree / sklearn.model_selection / matplotlib`

2

데이터 로드

`beverage_choices.csv` 파일 위치 확인 → `df = pd.read_csv()`

3

df 구조 확인

`df.head()` / `df.shape` / `df.info()` / `df.dtypes`

4

컬럼명 확인

`[temp, time_period, choice]` 3개 컬럼만 있는지 체크

5

데이터 분할

`train_test_split(X, y, test_size=0.2, random_state=42)`

데이터 탐색 — 음료 선택 데이터셋

□ 아이스(0) vs ☺ 핫(1) 선택을 기온(°C)과 시간대(오전/오후)로 예측

df.head() 결과 예상

```
temp  time_period  choice
18.5   오전         0
25.2   오후         1
15.3   오전         1
28.1   오후         0
...
```

시각화 (Scatter Plot)

기온 vs 선택: 저온→핫, 고온→아이스

시간대 vs 선택: 오전→핫, 오후→아이스

PART 2

손으로 하는 결정트리 — 지니 계산

전체 150개 데이터: 아이스 75개 / 핫 75개 → $Gini = 1 - (0.5^2 + 0.5^2) = 0.50$

Q1: 기온 $\geq 22^{\circ}\text{C}$?

예 (82개)

아이스 45 / 핫 37

$Gini = 0.495$

아니오 (68개)

아이스 30 / 핫 38

$Gini = 0.499$

정보 이득 = $0.50 - (82/150 \times 0.495 + 68/150 \times 0.499) = 0.0001$ (거의 없음!)

TODO 다른 질문들도 시도해보세요. (시간대? 기온 $\geq 20^{\circ}\text{C}$? 기온 $\geq 25^{\circ}\text{C}$?) 정보 이득이 가장 큰 질문을 루트로 선택합니다.

sklearn으로 자동 학습

```
from sklearn.tree import DecisionTreeClassifier, plot_tree

model = DecisionTreeClassifier(max_depth=3, random_state=42)
model.fit(X_train, y_train)  # 학습 수행

y_pred = model.predict(X_test)  # 테스트 예측

# 트리 시각화
plot_tree(model, feature_names=['temp', 'time_period'],
          class_names=['Ice', 'Hot'], filled=True)
```

주의 max_depth=3이면 트리가 너무 깊지 않아 과적합을 방지합니다. 9강에서 배운 처방을 직접 써보는 것! 나중에 이 값을 바꿔 성능 변화를 관찰합니다.

PART 4

혼동행렬과 평가지표 계산

```
from sklearn.metrics import confusion_matrix, accuracy_score, precision_score, recall_score
```

	예측 아이스	예측 핫
실제 아이스	TP (35)	FN (10)
실제 핫	FP (8)	TN (27)

정확도 $(35+27) / 80 = 0.775$

정밀도 $35 / (35+8) = 0.814$

재현율 $35 / (35+10) = 0.778$

깊이 조정으로 과적합 이해하기

max_depth를 1~6까지 바꿔 정확도 변화를 관찰한다

max_depth=1

훈련: 58%

테스트: 54%

너무 얕음

max_depth=2

훈련: 71%

테스트: 68%

약간 얕음

max_depth=3

훈련: 82%

테스트: 78%

☆ 적당

max_depth=4

훈련: 89%

테스트: 76%

깊음

max_depth=5

훈련: 96%

테스트: 72%

너무 깊음

max_depth=6

훈련: 100%

테스트: 68%

과적합

발견: 테스트 정확도가 최고인 지점이 '최적 깊이'. 그 너머는 훈련-테스트 격차 증가 = 과적합!

CHALLENGE

심화 문제

① 특성 중요도 분석

`model.feature_importances_`로 각 특성이 결정에 얼마나 기여하는지 시각화

② 다중 분류 확장

음료 선택을 3개 클래스(아이스/따뜻한 물/핫)로 확장해 학습

③ entropy vs gini

`criterion='entropy'`로 바꾼 뒤 결과 비교 — 불순도 척도에 따른 차이

④ 교차검증

`cross_val_score`로 안정성 평가 — 한 번의 `train_test_split`이 아닌 5-fold

⑤ 트리 해석 연습

`plot_tree` 결과를 보고 '기온 20도 오전'인 손님을 직접 분류해보기

WRAP - UP

실습을 마치며

- ✔ **결정트리 학습** 정보 이득으로 최적 질문을 탐욕적으로 선택 — 손 계산과 sklearn 학습이 동일
- ✔ **과적합과 제어** max_depth 제한으로 과적합 방지, 훈련-테스트 격차로 최적값 발견
- ✔ **성능 평가** 정확도만으로는 부족, 혼동행렬과 정밀도·재현율로 다각도 분석
- ✔ **sklearn 속달** fit / predict / 파라미터 조정 — 다음 모델도 이 패턴만 알면 쉬움